INSTITUTO FEDERAL
Norte de Minas Gerais
Campus Almenara

Graduação em Tecnologia em Análise e Desenvolvimento de Sistemas

DIEGO CARDOZO FERRAZ

MODELO PREDITIVO E ANÁLISE DA QUALIDADE DA ÁGUA USANDO TÉCNICAS DE APRENDIZADO DE MÁQUINA: UM ESTUDO DE CASO NO BAIXO VALE DO JEQUITINHONHA - MG.

Almenara - MG

2024

DIEGO CARDOZO FERRAZ

MODELO PREDITIVO E ANÁLISE DA QUALIDADE DA ÁGUA USANDO TÉCNICAS DE APRENDIZADO DE MÁQUINA: UM ESTUDO DE CASO NO BAIXO VALE DO JEQUITINHONHA - MG.

Trabalho apresentado à disciplina Trabalho de Conclusão de Curso II, do curso Análise e Desenvolvimento de Sistemas, como pré requisito para a conclusão do mesmo.

Instituto Federal de Educação Ciência e Tecnologia do Norte de Minas Gerais

Campus Almenara

Graduação em Tecnólogo em Análise e Desenvolvimento de Sistemas

Orientador: Profª. Suzana Viana Mota

Coorientador: Profº. Alan Teixeira de Oliveira

Almenara - MG

2024

DIEGO CARDOZO FERRAZ
MODELO PREDITIVO E ANÁLISE DA QUALIDADE DA ÁGUA USANDO TÉCNICAS DE APRENDIZADO DE MÁQUINA: UM ESTUDO DE CASO NO BAIXO VALE DO JEQUITINHONHA - MG./ DIEGO CARDOZO FERRAZ. – Almenara - MG, 2024-
59p. : il. (algumas color.) ; 30
Orientador: Profª. Suzana Viana Mota
Monografia
Instituto Federal de Educação Ciência e Tecnologia do Norte de Minas Gerais
Campus Almenara
Graduação em Tecnólogo em Análise e Desenvolvimento de Sistemas, 2024.
1. Palavra-chave1. 2. Palavra-chave2. 2. Palavra-chave3. I. Profª. Suzana Viana Mota. II. Instituto Federal de Educação, Ciência e Tecnologia do Norte de Minas Gerais. III. Campus Almenara. IV. MODELO PREDITIVO E ANÁLISE DA QUALIDADE DA ÁGUA USANDO TÉCNICAS DE APRENDIZADO DE MÁQUINA: UM ESTUDO DE CASO NO BAIXO VALE DO JEQUITINHONHA - MG.

"Porque Deus tanto amou o mundo que deu o seu Filho Unigênito,
para que todo o que nele crer não pereça,
mas tenha a vida eterna.
(Bíblia Sagrada, João 3, 16)

Diego Cardozo Ferraz

MODELO PREDITIVO E ANÁLISE DA QUALIDADE DA ÁGUA USANDO TÉCNICAS DE APRENDIZADO DE MÁQUINA: UM ESTUDO DE CASO NO BAIXO VALE DO JEQUITINHONHA - MG.

Trabalho apresentado à disciplina Trabalho de Conclusão de Curso II, do curso Análise e Desenvolvimento de Sistemas, como pré requisito para a conclusão do mesmo.

_____

Nome do Assinante

_____

Nome do Assinante

_____

Nome do Assinante

_____

Nome do Assinante

Almenara - MG

2024

Agradecimentos.

Primeiramente, quero agradecer a Deus, por essa trajetória, pela força, determinação e sabedoria ao longo desta jornada acadêmica. Sem Ele, eu não teria conseguido superar os desafios e chegar ao final deste curso, mesmo nos momentos em que pensei em desistir.

A conclusão deste trabalho também não seria possível sem as orações, bênçãos e apoio da minha avó, Eli Ferraz, e dos meus pais, Geraldo Ferraz e Eva Ferraz, que sempre me ofereceram conselhos, acreditaram em mim e estiveram presentes nas horas em que mais precisei. Agradeço também a toda minha família, cujo apoio e confiança foram essenciais para superar os desafios encontrados ao longo do caminho.

À minha orientadora, Suzana Vieira Mota, ao coorientador Alan Teixeira de Oliveira e à minha antiga orientadora, Valdete Maria Gonçalves de Almeida, expresso minha imensa gratidão pela dedicação, paciência e valiosas orientações que contribuíram significativamente para o desenvolvimento deste trabalho. Suas experiências e incentivos foram determinantes para a realização deste estudo.

Aos colegas e amigos que compartilharam esta trajetória, agradeço pelo apoio moral, pelas trocas de ideias e pelas discussões construtivas, que enriqueceram não só este trabalho, mas também minha experiência acadêmica.

Ao IFNMG - Campus Almenara, deixo meus agradecimentos pela oportunidade de aprendizado e pelos recursos oferecidos, que foram fundamentais para o desenvolvimento desta pesquisa.

Minha gratidão também à Roberta Pereira Matos, pelo fornecimento dos dados utilizados na pesquisa e pela confiança depositada na relevância deste trabalho.

Por fim, deixo meu reconhecimento a todos os professores, pesquisadores e colaboradores que, direta ou indiretamente, contribuíram para minha formação e para a finalização deste trabalho.

Muito obrigado a todos!

Resumo

A qualidade da água é um fator essencial para a saúde pública, sustentabilidade ambiental e desenvolvimento econômico. Este trabalho investiga o uso de aprendizado de máquina na análise da qualidade da água, utilizando duas bases de dados: uma pública do Kaggle, com 3.276 amostras, e outra menor, com 13 amostras coletadas em Rubim-MG, para validação. Os dados foram processados com técnicas adequadas para garantir a consistência e a qualidade. Foram avaliados algoritmos como KNN, Random Forest, Árvore de Decisão e SVM, com otimização de hiperparâmetros e validação cruzada. O KNN se destacou como o modelo mais eficaz, alcançando 63% de acurácia no treino, 62% no teste e 85% na validação, evidenciando sua eficácia na classificação da potabilidade, mesmo com dados limitados. Embora algumas métricas tenham ficado aquém do esperado devido à base de validação reduzida, os resultados confirmaram que o aprendizado de máquina pode superar limitações dos métodos tradicionais, especialmente na integração e análise de múltiplos parâmetros. As bases mais completas e bem alinhadas são fundamentais para aprimorar o desempenho e a generalização dos modelos, reforçando o aprendizado de máquina como uma ferramenta promissora para o monitoramento da qualidade hídrica.

Palavras-chave: Qualidade da água. Aprendizado de máquina. Potabilidade. Algoritmos de aprendizado. Validação.

Abstract

Water quality is a critical factor for public health, environmental sustainability, and economic development. This study investigates the use of machine learning for water quality analysis, utilizing two datasets: a public dataset from Kaggle with 3,276 samples and a smaller one with 13 samples collected in Rubim-MG for validation. The data were processed with appropriate techniques to ensure consistency and quality. Algorithms such as KNN, Random Forest, Decision Tree, and SVM were evaluated, with hyperparameter optimization and cross-validation. KNN stood out as the most effective model, achieving 63% accuracy on the training set, 62% on the test set, and 85% on the validation set, demonstrating its effectiveness in classifying water potability even with limited data. Although some metrics fell short due to the small validation set, the results confirmed that machine learning can overcome the limitations of traditional methods, especially in integrating and analyzing multiple parameters. More comprehensive and well-aligned datasets are crucial to improving model performance and generalization, reinforcing machine learning as a promising tool for water quality monitoring.

Keywords: Water quality. Machine learning. Potability. Learning algorithms. Validation.

Lista de ilustrações

Figura 1 – Processo KDD 15
Figura 2 – Exemplo: Árvore de Decisão 24
Figura 3 – Exemplo: KNN (K-Nearest Neighbors) 24
Figura 4 – Exemplo: Random Forest 25
Figura 5 – Exemplo 1: Algoritmo SVM para Classificação 26
Figura 6 – Exemplo 2: Tratando casos não linearmente separáveis - SVM 26
Figura 7 – Exemplo: Matriz de Confusão - métricas 28
Figura 8 – Exemplo: Acurácia 29
Figura 9 – Balanceamento das Amostras do Atributo de Potabilidade 38
Figura 10 – Tabela de Parâmetros Físico-Químicos e Potabilidade de Amostras de Água Rubim – MG. 39
Figura 11 – Proporção de dados ausentes por atributo na base de treino/teste. . . . 48
Figura 12 – Resultados das Matrizes de Confusão nos Conjuntos de Teste e Validação para Cada Algoritmo 50
Figura 13 – Precisão por Algoritmo 51
Figura 14 – Recall por Algoritmo 51
Figura 15 – Comparação do F1-Score 52
Figura 16 – Curva ROC 53
Figura 17 – Comparação de Acurácia entre Modelos (Teste vs Validação) 53

Lista de abreviaturas e siglas

ANVISA	Agência Nacional de Vigilância Sanitária
AM	Aprendizado de Máquina
AUC	Área Sob a Curva
CaCO3	Carbonato de Cálcio (Unidade de Dureza Total da Água)
CH	Inteligência Artificial
CP	Caminhão Pipa
CSH	Chuva Sem Hipoclorito de Sódio
CV	Cross-Validation (Validação Cruzada)
F1-Score	Média Harmônica entre Precisão e Recall
IFNMG	Instituto Federal do Norte de Minas Gerais.
IoT	Internet of Things (Internet das Coisas)
IA	Inteligência Artificial.
K-Fold	Validação Cruzada
IFNMG	Instituto Federal do Norte de Minas Gerais.
KDD	Descoberta de conhecimento em bancos de dados.
KNN	K-Nearest Neighbors (K- Vizinhos mais próximos)
OMS	Organização Mundial da Saúde
PCA	Análise de Componentes Principais
PA	Poços Artesianos
PtCo	Unidade de Platina-Cobalto (Cor da Água)
RF	Random Forest (Floresta Aleatória).
ROC	Receiver Operating Characteristic (Curva de Características Operacionais do Receptor)

SMOTE	Synthetic Minority Over-sampling Technique (Técnica de Sobreamostragem Sintética de Minorias)
SVM	Support Vector Machine (Máquina de Vetores de Suporte)
NTU	Unidade de Turbidez Nefelométrica.
ONU	Organização das Nações Unidas.
ppm	Partes por milhão.
TDS	Sólidos Dissolvidos Totais
THMS	Trihalometanos
VMP	Valor Máximo Permitido
S/cm	micro-Siemens por centímetro
TP	True Positive (Verdadeiro Positivo)
FP	False Positive (Falso Positivo)
TN	True Negative (Verdadeiro Negativo)
FN	False Negative (Falso Negativo)

Sumário

1 INTRODUÇÃO 13
1.0.1 Problema de Pesquisa 16
1.0.2 Hipótese 16

2 OBJETIVOS 17
2.1 Objetivo Geral 17
2.2 Objetivos Específicos 17

3 JUSTIFICA E RELEVÂNCIA 18

4 REFERENCIAL TEÓRICO 19
4.1 Qualidade da água 19
4.2 Inteligência Artificial e Avanços em Machine Learning 20
4.3 Conceitos e Técnicas Importantes sobre Machine Learning 22
4.3.1 Pré-processamento de dados 22
4.3.2 Modelos de Machine Learning 23
4.3.3 Procedimentos de Treinamento e Teste do Modelo 26
4.3.3.1 Seleção e Ajuste de Hiperparâmetros 27
4.3.4 Avaliação de Desempenho de Modelos: Principais Métricas 27
4.3.4.1 Uso de Bibliotecas como Scikit-Learn e Matplotlib 30

5 TRABALHOS RELACIONADOS 31
5.1 Análise da alcalinidade, cloretos, dureza, temperatura e condutividade em amostras de água do município de Almenara/MG. 31
5.2 Uso de Modelos de Aprendizado Supervisionado para Classificação da Potabilidade da Água 33
5.3 EcoWater, realizando o biomonitoramento da qualidade da água de forma inteligente 34

6 METODOLOGIA 36
6.1 Coleta e Descrição das baes de dados 37
6.2 Preparação dos Dados para Modelagem 40
6.2.1 Tratamento de Dados Ausentes 40
6.2.2 Normalização/Padronização 41
6.2.3 Balanceamento de Classes 41
6.2.4 Redução de Dimensionalidade com PCA 42
6.2.5 Divisão dos dados 43

6.3 Modelagem e Otimização dos Algoritmos ou Treinamento dos Modelos 44
6.4 Recursos Tecnológicos e Ferramentas Utilizadas 46

7 RESULTADOS E DISCUSSÕES 48
7.1 Análise Geral dos Resultados 49
7.2 Considerações Finais 54
7.2.1 Trabalhos Futuros 55

REFERÊNCIAS 56

1 Introdução

A qualidade da água potável é essencial para a saúde humana e a sustentabilidade ambiental. Segundo a Agência Nacional de Águas (ANA), a água só pode ser adequada para diversos usos quando há um monitoramento rigoroso de sua qualidade, tanto de águas superficiais quanto subterrâneas no país. Analisar e monitorar os parâmetros físicos e químicos da água são etapas fundamentais para assegurar sua potabilidade. Com o avanço da tecnologia, técnicas de Machine Learning têm sido aplicadas na análise de dados, proporcionando formas mais eficientes e precisas de monitorar e prever a qualidade da água.

Com o avanço das tecnologias e o crescente uso de ferramentas computacionais, técnicas de aprendizado de máquina (Machine Learning) têm sido progressivamente aplicadas na análise de dados de qualidade da água, proporcionando métodos mais eficientes e precisos para a previsão e monitoramento dessa qualidade. A automação do processo de análise de grandes volumes de dados com o uso de algoritmos de aprendizado de máquina oferece a possibilidade de aprimorar a acurácia na classificação da potabilidade da água, permitindo diagnósticos rápidos e eficazes (GÉRON, 2022).

Segundo Braun (1993) a água cobre 71% da superfície do planeta t erra, sendo encontrada nos oceanos e outras grandes massas de água. Destes, 97% estão nos oceanos e 2,4% em forma de gelo polar e geleiras. Apenas 0,6% estão em outras águas superficiais terrestres, como rios, lagos e lagoas. A água doce disponível em aquíferos subterrâneos representa uma pequena fração, enquanto uma quantidade muito pequena está no ar, como vapor, formando nuvens e resultando em precipitação. Dessa forma, a água doce, que é essencial para o consumo humano e o sustento dos ecossistemas, corresponde a menos de 3% de todo o volume de água do planeta (AKKARABOYINA; RAJU, 2012).

A água possui características físicas e químicas que indicam os parâmetros de potabilidade (BRAUN, 1993). A água doce e potável é um dos recursos naturais mais valiosos para todos os seres vivos, e a cada dia se torna mais urgente seu uso racional. A água potável é diferente da água pura (FUSATI, 2021). A Organização Mundial da Saúde (OMS) define a água potável como aquela que:

- É essencial para a sobrevivência humana e ambiental, com baixos níveis de salinidade e adequada para consumo humano, irrigação e sustento dos ecossistemas;
- Está livre de agentes patogênicos e substâncias tóxicas em níveis elevados;
- É usada para atividades essenciais, como ingestão, preparo de alimentos e higiene pessoal.

A poluição dos rios é uma preocupação crescente em diversas partes do mundo, inclusive em regiões como o Baixo Vale do Jequitinhonha. Embora não se possa afirmar com certeza sobre a situação local, a degradação dos rios na região pode ocorrer, visto que a poluição das águas é um fenômeno presente em muitos corpos hídricos em todo o planeta. Este fenômeno pode afetar diretamente a qualidade da água e, consequentemente, a saúde das populações que dependem desses recursos hídricos. Nesse contexto, é essencial a implementação de um controle rigoroso para preservar a qualidade da água, incluindo a fiscalização constante e o monitoramento das condições hídricas. A poluição das águas afeta diretamente ecossistemas e comunidades, sendo um problema global que impacta a agricultura, a indústria e, principalmente, a população humana. Diversos padrões de qualidade da água são estabelecidos para garantir seu uso adequado em consumo humano, recreação e indústrias. E com isso, é importante implementar medidas de tratamento e análise para garantir que a água disponível para consumo atenda aos padrões de segurança e pureza estabelecidos (PORTO, 2024).

A análise da qualidade da água abrange diversos parâmetros físicos e químicos fundamentais para determinar seu potencial de uso e tratamento. Testes físicos, como turbidez, cor, sólidos dissolvidos e odor, oferecem indicações visuais e sensoriais importantes sobre a pureza da água. Já os testes químicos, incluindo a medição de pH, dureza, condutividade elétrica, salinidade e presença de metais pesados, fornecem dados cruciais para avaliar a segurança e potabilidade da água. Esses parâmetros são essenciais para definir o tratamento adequado, influenciado por fatores naturais, como clima e condições geológicas, além de impactos das atividades humanas (APHA, 2005; CETESB, 2009). A qualidade da água, portanto, é resultado de um equilíbrio dinâmico entre influências naturais e intervenções antrópicas, sendo necessário monitoramento constante e uma análise integrada para garantir o uso seguro e sustentável do recurso (TUNDISI, 2016).

Diversos estudos e levantamentos já abordam os parâmetros necessários para medir a qualidade da água, sendo esses dados geralmente acessíveis ao público. Neste trabalho, foram desenvolvidos modelos preditivos que permitem classificar a qualidade da água com base nas suas características físicas e químicas. Juntamente, visa aplicar e avaliar diferentes algoritmos de aprendizado de máquina na análise da qualidade da água, utilizando dois conjuntos de dados distintos.

O primeiro conjunto, utilizado para treino e teste dos modelos, foi obtido a partir do repositório *"water potability"* [1] da plataforma Kaggle, uma das maiores comunidades de cientistas de dados. Já o segundo conjunto, utilizado para validação, foi fornecido por um levantamento realizado em colaboração com professores do IFNMG - Almenara, com base na pesquisa intitulada "Análise da qualidade da água para o consumo humano do

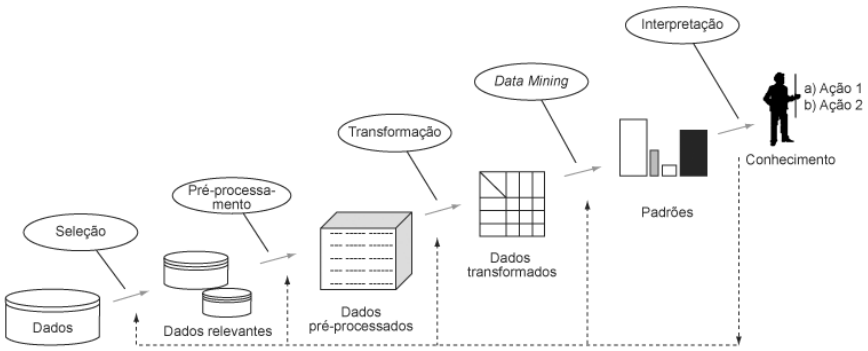
[1] https://www.kaggle.com/datasets/adityakadiwal/water-potability

assentamento Jerusalém no município de Rubim-MG" [2]. O estudo de caso foi realizado na região do Baixo Vale do Jequitinhonha-MG, com foco nas amostras de água de Rubim-MG. A validação dos modelos foi realizada por meio da comparação dos resultados obtidos entre os dois conjuntos de dados, considerando métricas para taxas de acertos.

A aplicação de técnicas de otimização de hiperparâmetros, foi fundamental para aprimorar o desempenho dos algoritmos, como KNN, Random Forest, SVM e Árvores de Decisão. Esses métodos permitiram ajustar os parâmetros dos modelos, maximizando a precisão e garantindo que os modelos de aprendizado de máquina fossem capazes de fornecer previsões confiáveis para a classificação da qualidade da água na região em estudo.

A abordagem utilizada para essa análise baseou-se no processo de Knowledge Discovery in Databases (KDD), que envolve desde a coleta de dados até a interpretação e avaliação dos resultados, conforme ilustrado na Figura 1:

Figura 1 – Processo KDD



Fonte: Elaborada por (STEINER et al., 2006)

Diversos algoritmos de aprendizado de máquina foram explorados, incluindo K-Nearest Neighbors (KNN), Random Forest, Support Vector Machine (SVM) e Árvores de Decisão. O KNN, por exemplo, baseia-se na proximidade entre os dados para realizar a classificação, identificando os pontos mais próximos para categorizar uma nova entrada (HASTIE et al., 2009). A Random Forest utiliza múltiplas árvores de decisão para aumentar a precisão do modelo, combinando os resultados de várias árvores individuais para reduzir a variância e melhorar a robustez do algoritmo (GÉRON, 2022). O SVM é conhecido por ser eficiente em lidar com dados de alta dimensionalidade, maximizando a margem entre as classes para realizar uma separação precisa entre elas (PEDREGOSA, 2011). As Árvores de Decisão, por sua vez, são úteis para interpretar os dados de forma hierárquica, facilitando a interpretação dos critérios de decisão e a visualização das condições que levam à classificação (HASTIE et al., 2009).

A metodologia adotada incluiu a utilização de validação cruzada para assegurar a robustez dos resultados, além de uma análise aprofundada das métricas de desempenho

[2] https://www.nucleodoconhecimento.com.br/engenharia-agricola/qualidade-da-agua

de cada algoritmo. O processo de análise de dados foi conduzido utilizando a linguagem Python, com o apoio de bibliotecas especializadas, como pandas, scikit-learn e matplotlib, que facilitaram o pré-processamento dos dados, a modelagem dos algoritmos e a geração de gráficos para comparação entre os algoritmos testados. A visualização gráfica dos resultados foi otimizada por essas bibliotecas, permitindo uma comparação clara e precisa entre os algoritmos testados. Esses procedimentos metodológicos asseguraram uma análise robusta e bem fundamentada dos algoritmos aplicados tanto nas amostras de treino e teste quanto nas de validação.

1.0.1 Problema de Pesquisa

Com o crescente volume de dados sobre a qualidade da água, torna-se essencial a utilização de técnicas avançadas de aprendizado de máquina para melhorar a análise e a avaliação da potabilidade. A análise tradicional muitas vezes não consegue lidar com a complexidade e a grande quantidade de dados, limitando a precisão na classificação (WITTEN et al., 2016).

Este estudo utiliza a base de dados *"water potability"* para treinamento e teste dos modelos e a base de dados de Rubim-MG como conjunto de validação. O problema de pesquisa é: Como aplicar técnicas de aprendizado de máquina para processar e analisar os dados de qualidade da água utilizando a base *"water potability"* para treinamento/teste e a base de Rubim-MG para validação, a fim de aprimorar a precisão e a eficácia na classificação e avaliação da potabilidade?

1.0.2 Hipótese

A aplicação de técnicas avançadas de aprendizado de máquina na análise dos dados de qualidade da água resultará em uma melhoria significativa na precisão da classificação da potabilidade, e a comparação entre os modelos preditivos demonstrará qual abordagem oferece o melhor desempenho, superando as limitações dos métodos tradicionais.

2 Objetivos

2.1 Objetivo Geral

Desenvolver e aplicar modelos de aprendizado de máquina para analisar e prever a qualidade da água, utilizando uma base de dados obtida de um repositório público para o treinamento e teste dos modelos, e avaliar a eficácia desses modelos utilizando uma base de dados específica de Rubim-MG para validação, com foco na precisão da classificação da potabilidade da água.

2.2 Objetivos Específicos

- Explorar estudos anteriores na literatura existente sobre técnicas de aprendizado de máquina aplicadas à análise de dados de qualidade da água para entender abordagens e métodos já utilizados e identificar as melhores práticas para o desenvolvimento de modelos preditivos.
- Identificar parâmetros relevantes e características que influenciam a avaliação da qualidade da água, com foco naqueles que têm impacto significativo na classificação e predição da qualidade da água.
- Implementar e treinar modelos preditivos de aprendizado de máquina utilizando dados disponíveis, aplicando técnicas apropriadas para construir modelos eficazes.
- Avaliar a precisão dos modelos preditivos desenvolvidos utilizando métricas de desempenho, como acurácia e precisão, para determinar sua capacidade de prever corretamente a qualidade da água.
- Testar e validar a eficácia dos modelos desenvolvidos utilizando amostras de água coletadas na região de Rubim-MG, no baixo Vale do Jequitinhonha-MG, para garantir que os modelos sejam adequados e eficazes para o contexto regional.

3 Justifica e Relevância

A análise da qualidade da água é essencial para a saúde pública, a preservação ambiental e o desenvolvimento econômico. No entanto, os métodos tradicionais de monitoramento enfrentam limitações ao lidar com a complexidade e o volume crescente de dados coletados. Nesse cenário, o aprendizado de máquina destaca-se como uma abordagem promissora, capaz de integrar e analisar múltiplos parâmetros físico-químicos de forma eficiente, proporcionando previsões mais precisas e rápidas.

Este estudo de caso investiga a aplicação de técnicas de aprendizado de máquina na análise de dados de qualidade da água, utilizando duas bases distintas: uma pública, do Kaggle, para treino e teste dos modelos, e outra regional, de Rubim-MG, para validação. Embora o objetivo principal seja acadêmico, o trabalho explora a viabilidade de modelos preditivos no contexto hídrico, sem pretensão imediata de impactar diretamente a gestão de recursos hídricos.

O aprendizado de máquina tem se mostrado eficaz na análise de grandes volumes de dados, especialmente ao identificar padrões complexos e melhorar a precisão das análises (DOMINGOS, 2015). Por meio do uso de algoritmos supervisionados e da aplicação de técnicas como pré-processamento e ajuste de hiperparâmetros, este estudo busca avaliar e aprimorar o desempenho dos modelos em contextos variados.

A relevância da pesquisa está em sua contribuição para o avanço acadêmico na aplicação de aprendizado de máquina a dados ambientais, integrando bases distintas para avaliar a robustez dos modelos em diferentes condições de entrada. Ao testar e validar modelos preditivos, o trabalho visa ampliar a compreensão sobre as potencialidades dessas tecnologias e seu papel em superar limitações práticas, fornecendo subsídios para estudos futuros na área.

4 Referencial Teórico

Para o referencial bibliográfico, com o propósito de dar todo o desenvolvimento para o conhecimento de estruturas necessárias para a compreensão deste trabalho, com o objetivo já definido serão tratados os conceitos da qualidade da água, métricas e indicadores, fonte de dados, mineração de dados, análise de dados preditiva, uso do Machine Learning, linguagem Python, testes com as bibliotecas como Pandas e Scikit-Learn escolhidas para o desenvolvimento do algoritmo.

4.1 Qualidade da água

A qualidade da água é um dos aspectos mais críticos para a saúde pública, sendo considerada um direito humano essencial, conforme definido pela Organização Mundial da Saúde (OMS) e pela legislação brasileira. Conforme Brasil (2021), o acesso à água potável é fundamental para prevenir doenças e garantir o bem-estar das populações. Segundo a Agência Nacional de Vigilância Sanitária (ANVISA) e o Ministério da Saúde, a água destinada ao consumo humano deve atender a uma série de parâmetros microbiológicos, físico-químicos e radiológicos, assegurando sua potabilidade.

A análise microbiológica da água é de extrema importância, pois permite identificar a presença de micro-organismos que indicam possíveis contaminações. A presença de coliformes fecais, por exemplo, é um forte indicativo de contaminação por esgoto, sinalizando um risco elevado de doenças como cólera, hepatite A, diarreia e outras infecções gastrointestinais (ANA, 2018). Essas doenças, em alguns casos, podem evoluir para quadros graves, principalmente em populações mais vulneráveis.

Além da análise microbiológica, os parâmetros físico-químicos também são essenciais para garantir a qualidade da água. O pH, por exemplo, é um indicador fundamental para avaliar o equilíbrio ácido-base da água. A OMS recomenda que o pH ideal esteja entre 6,5 e 8,5, a fim de garantir a compatibilidade com o organismo humano e evitar problemas como corrosão nas redes de distribuição (OMS, 2017).

Outros parâmetros físico-químicos relevantes incluem a dureza, que refere-se à concentração de íons de cálcio e magnésio na água. De acordo com o estudo de Brasil (2017), a dureza excessiva pode interferir na eficiência de detergentes e na qualidade das tubulações, enquanto a dureza muito baixa pode levar à corrosão. A ANVISA determina que a água potável deve possuir uma concentração de cálcio e magnésio que não exceda 500 mg/L, de acordo com o regulamento técnico de potabilidade.

A presença de sólidos dissolvidos totais (TDS) é outro fator crucial. Os TDS

indicam a quantidade de sais e minerais dissolvidos na água, e a ANVISA recomenda um limite máximo de 1000 mg/L para que a água seja considerada segura para consumo. Exceder esse limite pode significar um risco à saúde, uma vez que altas concentrações de substâncias como nitratos e sulfatos podem causar problemas renais e gastrointestinais (MINISTERIO, 2006).

Além disso, a condutividade elétrica da água está diretamente relacionada à presença de íons dissolvidos. A condutividade elevada pode indicar a presença de substâncias como sais de sódio e potássio, que, em excesso, podem tornar a água inadequada para consumo humano e industrial (ANA, 2018). Segundo a OMS, valores de condutividade acima de 400 µS/cm podem comprometer a qualidade da água potável.

A turbidez, que mede a presença de partículas suspensas na água, também é um parâmetro relevante. Segundo a ANVISA, níveis de turbidez superiores a 5 NTU indicam contaminação física, que pode estar associada à presença de micro-organismos patogênicos, aumentando o risco de transmissão de doenças (BRASIL, 2021). Além disso, substâncias como trihalometanos (THMs), subprodutos do processo de desinfecção da água com cloro, devem ser monitoradas. Os THMs são considerados potencialmente carcinogênicos, e seu limite máximo permitido pela ANVISA é de 80 µg/L (MINISTERIO, 2006).

Portanto, garantir a potabilidade da água depende de um conjunto de medidas de monitoramento e controle que envolvem tanto a análise microbiológica quanto os parâmetros físico-químicos. A regularidade desses testes é essencial para garantir que a água consumida pela população atenda aos padrões de segurança estabelecidos pelas autoridades competentes. Eventos imprevistos, como vazamentos químicos, demandam monitoramento adicional, pois podem alterar drasticamente a qualidade da água em curto prazo, exigindo respostas rápidas e eficazes para garantir a segurança hídrica (ANA, 2018).

4.2 Inteligência Artificial e Avanços em Machine Learning

A Inteligência Artificial (IA) refere-se ao campo da ciência da computação que desenvolve sistemas capazes de realizar tarefas que, tradicionalmente, requerem inteligência humana, como reconhecimento de padrões, tomada de decisões e aprendizado a partir de dados. Já o Aprendizado de Máquina (AM), uma subárea da IA, concentra-se no desenvolvimento de algoritmos que permitem que máquinas aprendam e melhorem seu desempenho sem a necessidade de programação explícita para cada tarefa (DOMINGOS, 2015).

Esses métodos estão se tornando indispensáveis em aplicações que envolvem grandes volumes de dados, como na análise ambiental, saúde e segurança, pois permitem a identificação de padrões complexos de maneira mais eficiente do que técnicas tradicionais.

O aprendizado de máquina (Machine Learning) é uma técnica que permite que sistemas identifiquem padrões em base em dados. Utilizando o reconhecimento de padrões e a aprendizagem a partir de exemplos, esses sistemas podem prever resultados, automatizar processos e melhorar a eficiência em diversas áreas. O aprendizado de máquina tornou-se uma ferramenta essencial na análise de grandes volumes de dados, facilitando a identificação de padrões e a realização de predições complexas. Sua eficácia advém da capacidade de aprender com dados históricos e aplicar esse conhecimento para prever resultados futuros, automatizando processos que anteriormente exigiam intervenção humana direta (GOODFELLOW; BENGIO; COURVILLE, 2016).

Existem diversos tipos de modelos preditivos que são aplicáveis a diferentes contextos, cada um com suas características e áreas de aplicação específicas. A escolha do modelo adequado depende da natureza dos dados e dos objetivos da análise (KUHN, 2013). Para o desenvolvimento deste trabalho, são empregados modelos de aprendizado supervisionado, que se baseiam em treinamento com dados rotulados. Nesse tipo de abordagem, o modelo é treinado utilizando um conjunto de dados rotulados, onde as entradas são associadas a saídas conhecidas. Após o treinamento, o modelo é utilizado para prever saídas a partir de novos dados de teste. Assim, o principal objetivo da técnica de aprendizado supervisionado é mapear a variável de entrada x com a variável de saída y (JAVATPOINT, 2022).

A aprendizagem supervisionada é uma das abordagens mais amplamente utilizadas em machine learning, sendo composta por diferentes técnicas que se adaptam a uma variedade de problemas. Dentre essas técnicas, as mais destacadas são a classificação e a regressão, cada uma com características e aplicações específicas, conforme descrito a seguir:

- Classificação: “O objetivo é atribuir rótulos a partir de um conjunto de classes predefinidas, sendo útil em problemas como a detecção de spam ou o reconhecimento de padrões em imagens” (JAMES et al., 2013).
- Regressão: “Visa prever um valor contínuo, sendo amplamente aplicada em áreas como a previsão de preços de imóveis ou de demanda energética, onde as saídas são variáveis numéricas contínuas” (HASTIE et al., 2009).

Nas subseções seguintes, serão discutidos os conceitos e técnicas essenciais para este estudo, com ênfase no pré-processamento de dados, desenvolvimento de modelos, escolha de algoritmos, seleção de características e otimização de hiperparâmetros visando maximizar a performance dos modelos. Além disso, será realizada uma comparação detalhada entre as abordagens e resultados obtidos neste trabalho e aqueles presentes na literatura, destacando semelhanças e diferenças significativas.

4.3 Conceitos e Técnicas Importantes sobre Machine Learning

Nesta subseção, serão discutidos conceitos e técnicas essenciais para a criação e compreensão de modelos preditivos. Serão abordados tópicos como o pré-processamento de dados, os diversos modelos de Machine Learning, o treinamento e a validação desses modelos, além das métricas utilizadas para avaliar seu desempenho.

4.3.1 Pré-processamento de dados

O pré-processamento de dados é uma etapa crucial no pipeline de Machine Learning, pois prepara os dados brutos para serem utilizados por algoritmos de aprendizado (HAN; PEI; TONG, 2022). Antes de aplicar modelos de Machine Learning, é necessário um pré-processamento cuidadoso dos dados, que envolve etapas. A seguir, serão abordados os principais procedimentos para preparar os dados não processados, garantindo que estejam prontos para serem utilizados de forma eficaz por algoritmos de Machine Learning:

(a) Limpeza dos dados

Esta etapa é crucial para garantir a qualidade e a precisão dos dados antes da análise, pois dados imprecisos ou incompletos podem levar a resultados enganosos. Técnicas comuns de limpeza incluem a remoção de duplicatas, a correção de erros tipográficos e o tratamento de valores ausentes (PYLE, 1999).

(b) Data Encoding

Realiza a transformação de dados categóricos em valores numéricos para análise com algoritmos de Machine Learning. Os métodos comuns incluem a codificação one-hot, que cria uma coluna binária para cada categoria, e a codificação de rótulos, que atribui um número único a cada categoria (GÉRON, 2022).

(c) Escalonamento de Dados

Essa etapa consiste em ajustar a escala das variáveis numéricas para melhorar a performance de algoritmos de Machine Learning que são sensíveis a diferenças de magnitude. Métodos comuns incluem a normalização, que ajusta valores para um intervalo fixo, e a padronização, que transforma os dados para uma distribuição com média zero e desvio padrão de um (JAMES et al., 2013).

(d) Dados desbalanceados

O tratamento de dados desbalanceados é essencial para evitar que modelos de Machine Learning fiquem enviesados em favor das classes majoritárias. Técnicas de reamostragem, como oversampling (aumentar a quantidade de exemplos da classe minoritária) e undersampling (reduzir a quantidade de exemplos da classe majoritária), são comumente aplicadas para equilibrar as classes. Métodos avançados, como

o SMOTE (Synthetic Minority Over-sampling Technique), criam exemplos sintéticos da classe minoritária para melhorar a distribuição dos dados (LEMAÃŽTRE; NOGUEIRA; ARIDAS, 2017).

Esse processo é fundamental para garantir que o modelo receba dados coerentes e sem ruídos, o que aumenta a precisão das previsões. A biblioteca Pandas, amplamente utilizada no pré-processamento, permite manipular e analisar dados de forma eficiente, sendo essencial para tarefas como o tratamento de valores ausentes, normalização dos dados e engenharia de atributos (MCKINNEY, 2010).

4.3.2 Modelos de Machine Learning

Neste estudo, foram analisados os modelos de classificação Árvores de Decisão, KNN (K-Nearest Neighbors), Random Forest e SVM (Support Vector Machine). A escolha desses modelos deve-se à sua relevância e eficácia na classificação de dados, contribuindo de forma significativa para a obtenção dos resultados.

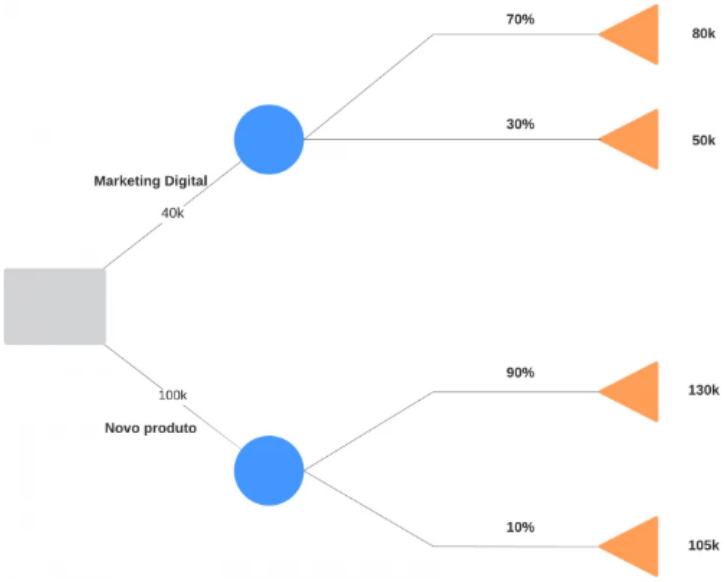
Considerando a vasta base teórica e estatística dos modelos mencionados, eles serão apresentados de forma sucinta, destacando suas características mais relevantes, bem como suas vantagens e limitações em diferentes contextos de análise de dados. A compreensão aprofundada desses modelos exige um estudo detalhado, já que cada um oferece abordagens específicas para problemas variados de classificação e regressão. Diversas fontes acadêmicas, como artigos científicos de impacto, livros reconhecidos na área de aprendizado de máquina e revistas especializadas, exploram de maneira abrangente esses modelos, proporcionando uma base sólida para sua aplicação em estudos reais. Além disso, recursos educacionais como tutoriais, cursos online e documentações de bibliotecas de código aberto oferecem suporte adicional para a implementação e otimização desses algoritmos, contribuindo para a contínua evolução de seu uso em áreas como ciência de dados e inteligência artificial.

I. **Árvore de Decisão**

O algoritmo de Árvore de Decisão utiliza uma estrutura hierárquica para tomar decisões, criando uma árvore onde cada nó representa uma pergunta sobre uma característica dos dados. A construção da árvore é guiada por critérios como ganho de informação ou redução da impureza de Gini, e a complexidade pode ser controlada através de técnicas de poda (KUHN, 2013). Segundo Breiman (2017) esse método é intuitivo e fácil de interpretar, mas pode sofrer com overfitting ao se ajustar excessivamente aos dados de treinamento, o que prejudica sua performance em novos dados. Isso é especialmente problemático se a árvore for muito profunda e complexa. A poda é uma técnica comum para simplificar a árvore e melhorar a generalização do modelo.

A seguir, um exemplo de árvore de decisão de classificação:

Figura 2 – Exemplo: Árvore de Decisão

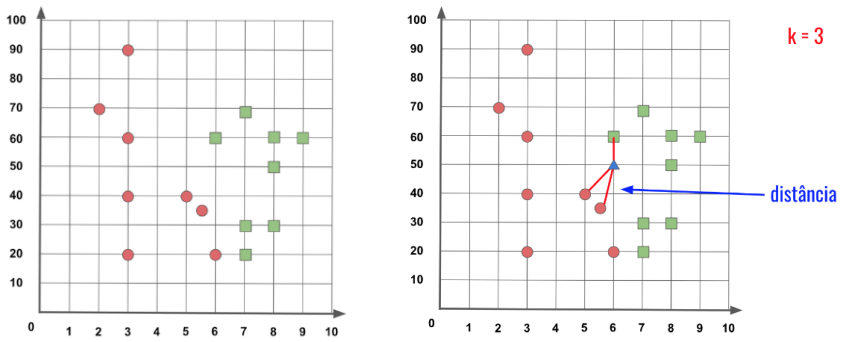


Fonte: Elaborada por (MáQUINA, 2020)

II. KNN (K-Nearest Neighbors)

O KNN é um algoritmo de aprendizado não paramétrico que classifica novas amostras com base na proximidade de amostras previamente rotuladas. A escolha do número de vizinhos (k) e a métrica de distância utilizada são cruciais para o desempenho do algoritmo (ALTMAN, 1992). A simplicidade e a eficácia do KNN o tornam adequado para problemas de classificação e regressão, porém, seu desempenho pode ser afetado por dados desbalanceados e a escolha do valor de k. Além disso, a performance do KNN pode ser afetada pela métrica de distância utilizada, como a distância Euclidiana ou Manhattan, e pela escala dos dados, o que pode ser mitigado por técnicas de escalonamento, como normalização (COVER; HART, 1967).

Figura 3 – Exemplo: KNN (K-Nearest Neighbors)

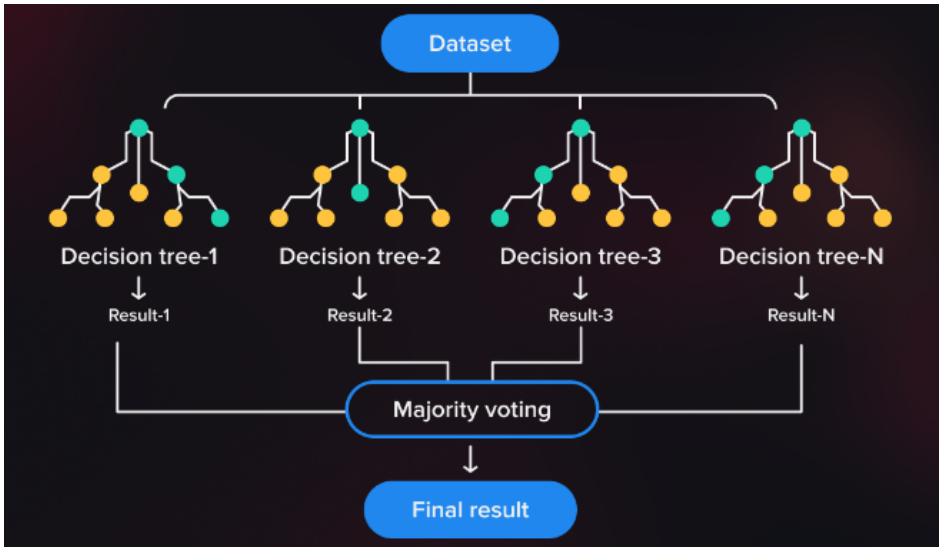


Fonte: Elaborada por (SAKURAI, 2024)

III. Random Forest

Esse modelo é amplamente utilizado em diversas aplicações, como detecção de fraudes, classificação de imagens e análise de mercado, devido à sua flexibilidade e alta precisão. Cada árvore de decisão do Random Forest é treinada em um subconjunto diferente dos dados, e a divisão das características em cada nó é feita com base em um subconjunto aleatório das variáveis (CUTLER et al., 2007). O algoritmo é eficaz na captura de padrões não lineares e se destaca em problemas onde outros modelos, como regressão linear ou simples árvores de decisão, falham. Além disso, o Random Forest é inerentemente capaz de fornecer uma estimativa da importância de cada característica, o que facilita a interpretação dos dados e a identificação de variáveis-chave para o modelo (LIAW; WIENER et al., 2002).

Figura 4 – Exemplo: Random Forest

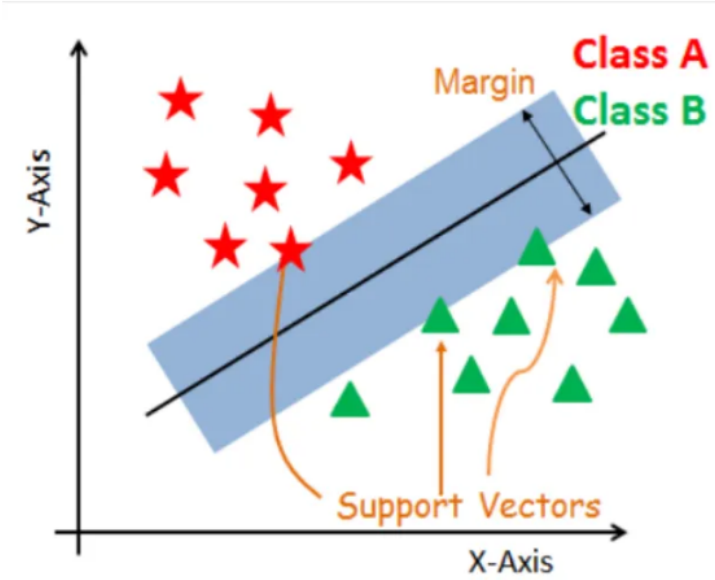


Fonte: Elaborada por (LOGUNOVA, 2022)

IV. SVM (Support Vector Machine)

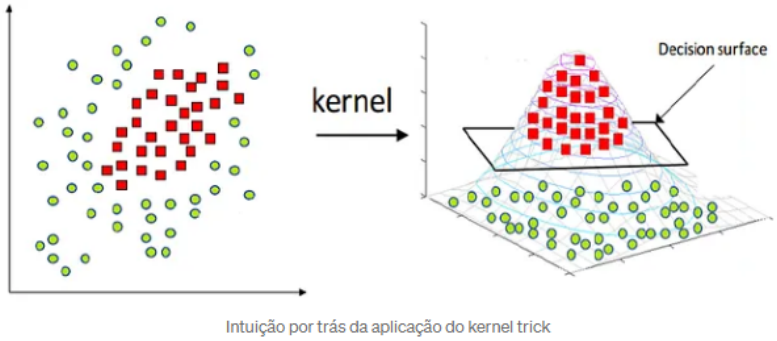
É um algoritmo de aprendizado supervisionado amplamente utilizado para tarefas de classificação e regressão, no qual, o seu principal objetivo é encontrar o hiperplano ótimo que separa as classes de dados de forma maximizada, ou seja, com a maior margem possível entre os pontos de dados das classes diferentes (CORTES, 1995). A principal característica é sua flexibilidade através do uso de funções de kernel, que permitem transformar dados não linearmente separáveis em um espaço de características de dimensões superiores, onde se torna possível traçar um hiperplano linear de separação (BURGES, 1998).

Figura 5 – Exemplo 1: Algoritmo SVM para Classificação



Fonte: Elaborada por (VINICIUSSEGATTO, 2023).

Figura 6 – Exemplo 2: Tratando casos não linearmente separáveis - SVM



Fonte: Elaborada por (LUCAS, 2024).

4.3.3 Procedimentos de Treinamento e Teste do Modelo

Para cada modelo selecionado, é fundamental realizar o processo de treinamento e teste para avaliar seu desempenho de forma eficaz. Durante o treinamento, o modelo é exposto a um conjunto de dados rotulados, permitindo que ele aprenda os padrões e as relações entre as variáveis de entrada e a variável de saída. Esses modelos podem ser desenvolvidos de várias maneiras, dependendo da divisão dos dados e do método aplicado:

1. A divisão do conjunto de dados em partes para treinamento e teste é fundamental para garantir que o modelo não só tenha bom desempenho nos dados de treinamento, mas também seja capaz de generalizar para novos dados (SANTOS et al., 2019). A

base de treino (contendo, por exemplo, 70% dos dados originais) e a base de teste (contendo, o restante dos dados originais, no caso, 30%), a partir de uma base de dados rotulada (ESCOVEDO, 2020).

2. A base de dados pode ser dividida em treinamento, validação e teste. Segundo Goodfellow, Bengio e Courville (2016), o conjunto de treinamento é usado para ajustar os parâmetros do modelo, enquanto o conjunto de validação serve para afinar hiperparâmetros e evitar overfitting. Já o conjunto de teste é reservado para avaliar a performance final do modelo em dados inéditos. Esse processo de separação dos dados é crucial para garantir que o modelo não apenas memorize os exemplos vistos durante o treinamento, mas também seja capaz de fazer boas previsões em novos dados.

3. Dividir os dados em apenas dois subconjuntos, como treinamento e teste, pode resultar em avaliações menos precisas do modelo, devido à variabilidade nas informações contidas em cada parte. A validação cruzada por K-fold é uma técnica recomendada para reduzir esse impacto. Nesse método, os dados são divididos em K partes iguais, onde o modelo é ajustado em K-1 partes, enquanto a parte restante é usada para validação. Esse processo é repetido K vezes, garantindo que cada parte seja usada para validação uma vez. Ao final, a média dos K resultados oferece uma estimativa mais robusta do desempenho do modelo, proporcionando maior confiabilidade na avaliação e reduzindo a chance de overfitting (KUHN, 2013).

4.3.3.1 Seleção e Ajuste de Hiperparâmetros

A seleção de hiperparâmetros é uma etapa crucial para otimizar a performance dos algoritmos. Métodos como o GridSearchCV e o RandomizedSearchCV são empregados para testar diversas combinações de parâmetros e identificar a configuração que oferece o melhor desempenho para um determinado modelo (BERGSTRA; BENGIO, 2012). Esses métodos são especialmente úteis quando aplicados a algoritmos como SVM e Random Forest, pois permitem ajustar parâmetros como o número de árvores (no caso do Random Forest) ou a constante de penalidade (no caso do SVM), aumentando a eficácia do modelo.

4.3.4 Avaliação de Desempenho de Modelos: Principais Métricas

Ao desenvolver e comparar diferentes modelos de classificação, é fundamental utilizar métricas adequadas para a avaliação de desempenho. Cada métrica oferece uma perspectiva distinta sobre a eficácia do modelo (POWERS, 2020). Neste estudo, serão analisadas métricas essenciais para a avaliação dos artigos e para o desenvolvimento do projeto, destacando a matriz de confusão, precisão, revocação, acurácia e F1 Score. A

utilização dessas métricas permitirá uma avaliação detalhada do desempenho dos modelos de classificação empregados.

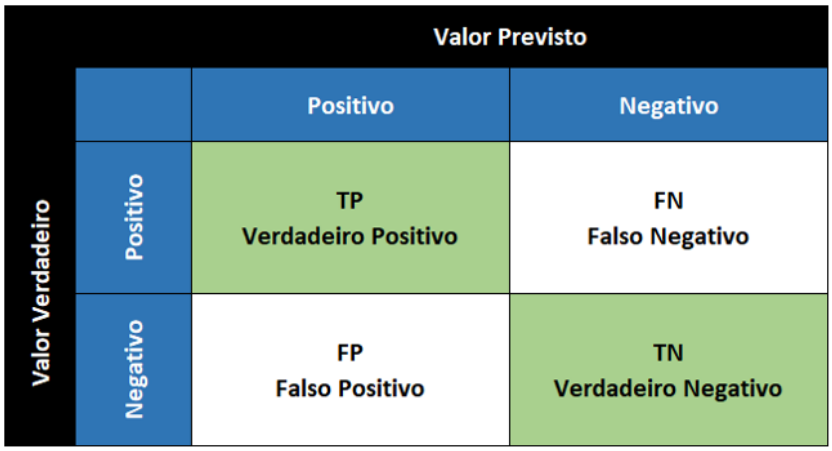
(a) **Matriz de Confusão**

A matriz de confusão é amplamente utilizada para avaliar o desempenho de modelos de classificação binária, oferecendo uma representação detalhada das previsões corretas e incorretas feitas pelo modelo (SAMMUT; WEBB, 2011). Os elementos principais da matriz de confusão são:

- **Verdadeiros Positivos (VP)** Casos em que o modelo previu corretamente a classe negativa.
- **Verdadeiros Negativos (VN)** Casos em que o modelo previu a classe positiva incorretamente (erro tipo I).
- **Falsos Positivos (FP)**: Casos em que o modelo previu a classe negativa incorretamente (erro tipo II).
- **Falsos Negativos (FN)**: Casos em que o modelo previu a classe negativa incorretamente (erro tipo II).

Esses elementos são essenciais para calcular métricas como precisão, revocação, acurácia e F1-Score, fornecendo uma visão mais detalhada do desempenho do modelo além da taxa de acertos geral (PROVOST, 2013).

Figura 7 – Exemplo: Matriz de Confusão - métricas



Fonte: Elaborada por (KARPINSKI, 2018).

(b) **Acurácia**

A acurácia é a razão de total de acertos sobre o número total de itens:

Figura 8 – Exemplo: Acurácia

$$acurácia = \frac{Total\ de\ acertos}{Total\ de\ itens}$$

Fonte: Elaborada por (MARIANO, 2021).

A métrica de acurácia é calculada somando os verdadeiros positivos (VP) e negativos (VN), e dividindo pelo total de exemplos, incluindo falsos positivos (FP) e negativos (FN). Porém, em classes desbalanceadas, pode ser enganosa, já que um modelo que prevê sempre a classe maioritária pode parecer eficaz, mas falha em identificar a classe minoritária (SOKOLOVA; LAPALME, 2009).

- Acurácia $= \frac{VP+VN}{VP+FN+VN+FP}$

(c) **Precisão e Revocação**

A precisão é uma métrica que mede a proporção de previsões corretas feitas pelo modelo em relação ao total de previsões positivas (POWERS, 2020). Esta métrica: $Precisão = \frac{VP}{VP+FP}$ é particularmente relevante em cenários onde o custo de previsões falsas positivas é alto (SOKOLOVA; LAPALME, 2009).

A revocação, também chamada de sensibilidade, é uma métrica que avalia a capacidade do modelo de identificar corretamente todos os exemplos positivos (MANNING, 2008). Essa métrica: $Revocação = \frac{VP}{VP+FN}$ é essencial quando a prioridade é minimizar falsos negativos, como em diagnósticos médicos (HAN; KAMBER; PEI, 2012).

(d) **F1-Score**

O F-Score, ou F1-Score, é uma métrica que combina precisão e revocação em uma única medida, especialmente útil quando há um desequilíbrio entre as classes (HAN; KAMBER; PEI, 2012). O F1-Score é indicado quando tanto falsos positivos quanto falsos negativos são relevantes para a avaliação do modelo, sendo amplamente utilizado em tarefas como classificação de texto e detecção de fraudes (POWERS, 2020).

- F1 * 2 $= \frac{Precisão * Sensibilidade}{Precisão + Sensibilidade}$

(e) **Curvas ROC e AUC**

A Curva Receiver Operating Characteristic (ROC) e a Área Sob a Curva (AUC) são ferramentas fundamentais na avaliação de modelos de classificação binária. A Curva ROC ilustra a relação entre a taxa de verdadeiros positivos (sensibilidade) e a taxa de falsos positivos (1 - especificidade) em diversos limiares de decisão, proporcionando uma visão abrangente da capacidade discriminativa do modelo. A AUC quantifica essa habilidade em um único valor, variando de 0 a 1, onde valores próximos a 1 indicam excelente desempenho. Estudos recentes destacam a aplicação dessas métricas em diversas áreas. Por exemplo, a análise de curvas ROC tem sido utilizada para avaliar marcadores funcionais em diagnósticos médicos, auxiliando na identificação de biomarcadores eficazes (BIANCO; BOENTE; PARDO-FERNáNDEZ, 2024). Além disso, pesquisas têm explorado as incertezas associadas às curvas ROC derivadas de dados de contagem, visando aprimorar a interpretação e a confiabilidade dessas análises (FEWELL, 2024).

- $AUC = \int_0^1 TPR(FPR)d(FPR)$

4.3.4.1 Uso de Bibliotecas como Scikit-Learn e Matplotlib

No contexto do estudo de caso, bibliotecas como Scikit-Learn e Matplotlib são ferramentas indispensáveis. Scikit-Learn fornece uma ampla variedade de algoritmos e métodos de avaliação, como KNN, Random Forest, SVM e Árvore de Decisão, além de ferramentas para pré-processamento e ajuste de hiperparâmetros (PEDREGOSA, 2011). Já a Matplotlib é utilizada para visualização de dados, permitindo plotar gráficos como matrizes de confusão, curvas ROC e histogramas, que auxiliam na interpretação dos resultados de maneira clara e visual.

5 Trabalhos Relacionados

Na revisão da literatura, foram identificados três trabalhos relevantes que tratam de aspectos relacionados à análise da qualidade da água, utilizando, em diferentes níveis, técnicas de aprendizado de máquina.

O primeiro estudo, intitulado “Análise da alcalinidade, cloretos, dureza, temperatura e condutividade em amostras de água do município de Almenara/MG”, realiza uma análise dos parâmetros físicos e químicos da água, focando na avaliação da qualidade hídrica da cidade de Almenara-MG.

O segundo trabalho, intitulado “Uso de Modelos de Aprendizado Supervisionado para Classifi- cação da Potabilidade da Água”, investiga a aplicação de técnicas de aprendizado de máquina na classificação da potabilidade da água, analisando algoritmos e destacando sua eficácia na avaliação de parâmetros físico-químicos.

Por fim, o estudo “EcoWater, realizando o biomonitoramento da qualidade da água de forma inteligente”, propõe uma abordagem inovadora, utilizando inteligência artificial para o monitoramento contínuo da qualidade da água.

Esses trabalhos contribuem significativamente para o desenvolvimento deste estudo, abordando aspectos essenciais da qualidade da água, como análise de parâmetros físico-químicos, aplicação de algoritmos de aprendizado supervisionado e integração de inteligência artificial no monitoramento contínuo. As metodologias e resultados apresentados fornecem suporte teórico e prático para aprimorar os modelos de aprendizado de máquina aplicados à análise da qualidade da água na região do Baixo Vale do Jequitinhonha-MG.

5.1 Análise da alcalinidade, cloretos, dureza, temperatura e condutividade em amostras de água do município de Almenara/MG.

O estudo dos professores do IFNMG - Campus Almenara-MG, teve como principal objetivo analisar a qualidade da água proveniente de diferentes pontos de cole ta no município de Almenara, localizado no Vale do Jequitinhonha, Minas Gerais. A pesquisa se concentrou em parâmetros físico-químicos fundamentais, como alcalinidade, cloretos, dureza, temperatura e condutividade elétrica, essenciais para determinar a potabilidade e a segurança da água consumida pela população local (REIS; GAMA; MATOS, 2021).

Para a realização do estudo, amostras de água foram coletadas em locais estratégicos, como fontes de abastecimento e corpos d’água utilizados pela comunidade. Em seguida, essas amostras foram submetidas a uma série de análises laboratoriais. Cada parâmetro

investigado tem importância no contexto de qualidade da água:

- Alcalinidade: Refere-se à capacidade da água de neutralizar ácidos e é um indicativo de sua estabilidade química. No estudo, a alcalinidade foi medida para verificar a capacidade de tamponamento da água, que influencia a resistência à variação de pH.
- Cloretos: Esse parâmetro é um indicador da presença de sais dissolvidos, principalmente cloreto de sódio (NaCl), e sua concentração excessiva pode indicar poluição por esgoto doméstico ou industrial.
- Dureza: Ela está associada à concentração de íons de cálcio (Ca^2+) e magnésio (Mg^2+) na água. Esse fator influencia não apenas a saúde humana, mas também a durabilidade de tubulações e equipamentos.
- Temperatura: Esse parâmetro da água afeta outros fatores como a solubilidade de gases, a condutividade elétrica e as reações químicas.
- Condutividade Elétrica: Esse é uma medida da capacidade da água de conduzir eletricidade, o que está relacionado à concentração de íons dissolvidos, como sais minerais. A condutividade alta pode ser um indicativo de poluição ou contaminação.

Os resultados das análises revelaram variações significativas nos parâmetros testados, dependendo do ponto de coleta. Em alguns locais, a alcalinidade e a dureza se mostraram acima dos níveis aceitáveis, o que pode indicar a presença de fatores naturais ou antropogênicos que impactam a qualidade da água. A condutividade elétrica também apresentou valores elevados em algumas amostras, sugerindo a possível presença de poluentes dissolvidos. No entanto, os níveis de cloretos permaneceram dentro dos padrões estabelecidos pelas normas de qualidade de água para consumo humano.

Os achados deste estudo são de grande relevância para a gestão dos recursos hídricos na região de Almenara. Eles indicam a necessidade de um monitoramento contínuo e de medidas de mitigação para garantir que a água atenda aos padrões de potabilidade. Além disso, o estudo sugere que a combinação de técnicas tradicionais de análise de qualidade da água com abordagens mais modernas, como o uso de aprendizado de máquina, pode ser uma solução eficaz para a predição e controle de parâmetros críticos em sistemas de abastecimento.

Este trabalho serve como uma referência importante para a análise de qualidade da água na região do Vale do Jequitinhonha e fornece um ponto de partida valioso para o desenvolvimento de modelos preditivos mais avançados, como os propostos no presente estudo. A abordagem detalhada dos parâmetros de qualidade da água e a relevância dos resultados mostram que há uma oportunidade clara para a aplicação de técnicas

de aprendizado de máquina para otimizar a análise e o monitoramento contínuo desses parâmetros, contribuindo para a segurança hídrica da população local.

5.2 Uso de Modelos de Aprendizado Supervisionado para Classificação da Potabilidade da Água

De acordo Porto (2024), essa dissertação trata-se da aplicação de aprendizado supervisionado para a classificação da potabilidade da água, com foco na eficiência de modelos preditivos em um contexto ambiental e de saúde pública. O estudo utilizou a base de dados *"water potability"* do Kaggle, composta por 3276 registros com atributos físico-químicos como pH, dureza, sólidos dissolvidos, e cloro residual, que serviram como variáveis explicativas para determinar se a água é potável ou não-potável.

O processo metodológico foi dividido em diversas etapas, com destaque para:

1. Pré-processamento de Dados

    - Tratamento de valores ausentes por meio de imputação, utilizando a média para dados contínuos.
    - Balanceamento da base de dados com a técnica SMOTE (Synthetic Minority Oversampling Technique), para lidar com a desproporção das classes potável e não potável.
    - Normalização dos atributos físico-químicos para uniformizar a escala e melhorar o desempenho dos algoritmos.

2. Implementação dos Algoritmos Foram testados diversos modelos supervisionados, incluindo:

    - Naive Bayes, que usa probabilidades para classificar os dados.
    - Random Forest, um ensemble baseado em árvores de decisão.
    - Support Vector Machine (SVM), que busca maximizar a margem entre as classes.
    - Outros algoritmos, avaliados em função da eficácia e do desempenho em métricas predefinidas.

3. Métricas de Avaliação A eficácia dos modelos foi avaliada com base em métricas como:

- Acurácia, que mede a proporção de previsões corretas.
- Área sob a curva ROC (AUC), que avalia a capacidade de separação entre classes.
- Precisão, para identificar a proporção de predições corretas de água potável.

Já nos resultados, O estudo demonstrou que o SVM foi o modelo mais eficaz, alcançando uma acurácia de 87% no conjunto de teste. A Random Forest também apresentou bons resultados, especialmente na análise da importância das variáveis, identificando atributos como pH e sólidos dissolvidos como os mais relevantes. Já o Naive Bayes teve desempenho inferior, devido à sua limitação em modelar a complexidade dos dados.

O trabalho evidencia a relevância de técnicas de aprendizado de máquina para análise da qualidade da água. Os modelos desenvolvidos não apenas superam métodos tradicionais em termos de precisão, mas também oferecem uma abordagem escalável para problemas semelhantes. A pesquisa destaca o potencial do aprendizado de máquina na gestão e monitoramento de recursos hídricos, apontando para futuras aplicações na detecção precoce de contaminações e na formulação de políticas públicas.

Além disso, o uso de ferramentas como Python e bibliotecas especializadas (pandas, scikit-learn e matplotlib) foi fundamental para o sucesso do estudo, permitindo a execução eficiente de análises complexas e a visualização dos resultados.

5.3 EcoWater, realizando o biomonitoramento da qualidade da água de forma inteligente

Segundo Chagas (2017), este trabalho propõe uma abordagem inovadora para o monitoramento da qualidade da água, utilizando sensores e inteligência artificial (IA) em um sistema automatizado. O objetivo do estudo foi desenvolver uma plataforma que usa aprendizado de máquina para analisar dados coletados por sensores em corpos hídricos, permitindo o acompanhamento contínuo dos parâmetros da água essenciais.

O sistema EcoWater foi projetado para realizar biomonitoramento de forma autônoma, empregando tecnologias emergentes como IoT e IA. Sensores instalados em pontos estratégicos coletam dados sobre pH, turbidez, temperatura, oxigênio dissolvido, condutividade elétrica, entre outros, transmitindo-os para uma plataforma central que utiliza algoritmos de aprendizado de máquina para analisar os valores e prever mudanças na qualidade da água.

Uma das vantagens dessa solução é a detecção precoce de anomalias, como poluição por esgoto ou resíduos industriais, permitindo alertas antes que os problemas se agravem,

superando as limitações dos métodos tradicionais de análise. O estudo também destaca a eficácia de modelos preditivos, como redes neurais artificiais (RNA) e máquinas de vetores de suporte (SVM), que contribuíram para um monitoramento mais eficiente.

Além disso, o sistema EcoWater é escalável, podendo ser adaptado desde pequenos corpos hídricos até grandes sistemas de abastecimento. A utilização de dispositivos IoT de baixo custo torna a solução acessível a regiões com recursos limitados.

Os resultados obtidos foram promissores, com alta precisão na previsão dos parâmetros críticos e identificação de anomalias de forma antecipada, permitindo intervenções oportunas. O uso de IA no biomonitoramento reduziu a necessidade de amostragens manuais, diminuindo custos operacionais e aumentando a eficiência do monitoramento.

Este estudo é relevante para o presente trabalho, pois demonstra como a integração de tecnologias inteligentes com aprendizado de máquina pode otimizar o monitoramento da qualidade da água.

6 Metodologia

O presente trabalho caracteriza-se como uma pesquisa aplicada, voltada para solucionar o problema prático da análise e predição da potabilidade da água na região do Baixo Vale do Jequitinhonha, utilizando técnicas de aprendizado de máquina. Adotando o processo de Descoberta de Conhecimento em Bases de Dados (KDD, Knowledge Discovery in Databases), esta pesquisa segue um fluxo estruturado para transformar dados brutos em informações úteis e relevantes. O estudo busca gerar insights significativos sobre a qualidade da água na região, contribuindo para o entendimento dos fatores que influenciam sua potabilidade.

Configura-se como uma pesquisa quantitativa, envolvendo a coleta e análise de dados numéricos — tais como pH, dureza e turbidez —, além do uso de modelos estatísticos e algoritmos matemáticos para a predição. Ademais, trata-se de um estudo de caso, aplicando técnicas específicas ao contexto local, com foco na região de Rubim-MG.

O processo KDD orientou cada etapa do desenvolvimento do trabalho, começando pela seleção dos dados, que envolveu a coleta de duas bases: uma pública, extraída do repositório *water potability* do Kaggle, utilizada para treino e teste, e outra, menor, composta por amostras coletadas em Rubim-MG, usada para validação. Na sequência, o pré-processamento foi realizado para tratar valores ausentes, ajustar a escala dos atributos e balancear as classes no atributo "Potabilidade".

Transformações adicionais foram aplicadas, como a redução de dimensionalidade por meio do PCA (Principal Component Analysis), preparando os dados para a etapa de modelagem. Os algoritmos KNN, Random Forest, Árvore de Decisão e SVM foram utilizados na mineração de dados, com otimização de hiperparâmetros e validação cruzada para aprimorar o desempenho. Por fim, a avaliação incluiu métricas como acurácia, F1-Score e AUC, além de uma análise detalhada das matrizes de confusão.

Após a caracterização do trabalho, a primeira atividade desenvolvida consistiu em um levantamento bibliográfico, cuja finalidade foi obter informações relevantes para o tema da pesquisa. Desse modo, “não se busca milhões de textos sobre um conceito genérico, mas informação precisa e relevante” (GALVÃO, 2010). Esse levantamento forneceu embasamento teórico para a compreensão dos fatores que influenciam a qualidade da água e destacou a importância dos dados coletados sobre a água na região do Baixo Vale do Jequitinhonha para a análise do estudo.

6.1 Coleta e Descrição das baes de dados

Neste trabalho, foram utilizadas duas bases de dados distintas que fornecem informações sobre a qualidade da água na região do Baixo Vale do Jequitinhonha - MG.

A primeira base de dados foi obtida na plataforma Kaggle [1], uma das maiores repositórias de dados científicos disponíveis para a comunidade de pesquisa e análise de dados. Organizada por Aditya Kadiwal, esta base de dados concentra-se na análise de potabilidade da água, fornecendo diversos parâmetros físico-químicos que influenciam na qualidade da água. Entre os atributos presentes na base estão:

- pH: mede o nível de acidez ou alcalinidade da água. O valor de pH é um indicador fundamental da qualidade da água, influenciando tanto sua potabilidade quanto seu impacto nos ecossistemas locais.
- Dureza: representa a concentração de minerais, como cálcio e magnésio, que podem afetar o gosto da água e a formação de incrustações em encanamentos.
- Cloretos: o teor de cloreto pode afetar o gosto da água e também ser um indicativo de contaminação.
- Sulfatos: quantidades excessivas de sulfato podem resultar em problemas gastrointestinais.
- Condutividade: mede a capacidade da água de conduzir eletricidade, diretamente relacionada à presença de íons dissolvidos.
- Turbidez: relaciona-se à quantidade de partículas suspensas na água, afetando sua clareza e, em alguns casos, indicando possíveis contaminações microbiológicas.
- Carbono Orgânico: representa a quantidade de matéria orgânica dissolvida na água, sendo um indicador importante da qualidade da água e podendo influenciar na formação de subprodutos de desinfecção.
- Trihalometanos: compostos orgânicos que podem ser formados durante o processo de desinfecção da água por cloro. O excesso de trihalometanos pode ser prejudicial à saúde.
- Cloraminas: compostos utilizados na desinfecção da água, sendo alternativas ao cloro livre, que ajudam a reduzir a formação de subprodutos como os trihalometanos.

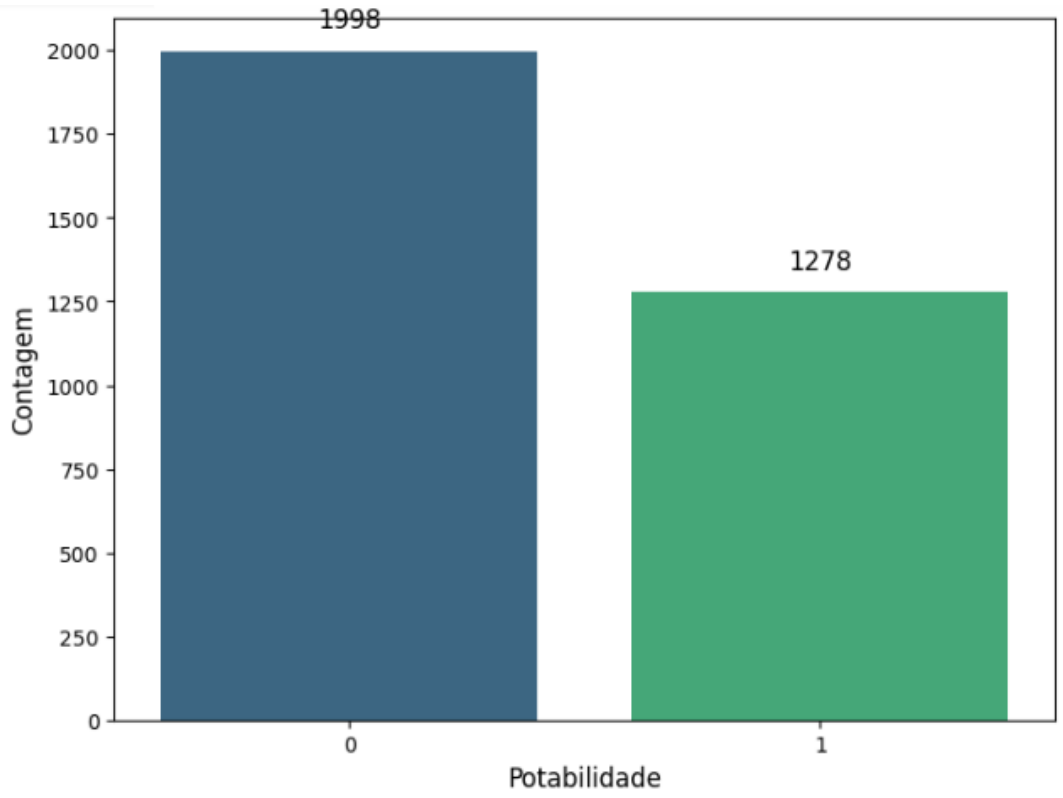
Além desses atributos, a base inclui o parâmetro potabilidade, que é utilizado como variável alvo no presente estudo. Este atributo é de extrema importância, pois classifica

[1] https://www.kaggle.com/datasets/adityakadiwal/water-potability

a água em dois grupos: potável e não potável, o que permite a aplicação de técnicas de aprendizado de máquina para prever a potabilidade da água com base nas características mencionadas.

Durante a análise exploratória inicial, foi observado o desbalanceamento entre as classes do atributo potabilidade. A Figura 9 apresenta o balanceamento das amostras, evidenciando que a classe "não potável" (0) possui uma quantidade ligeiramente superior à classe "potável" (1). Essa informação foi considerada no desenvolvimento das etapas subsequentes de modelagem, garantindo que o desbalanceamento não comprometesse o desempenho dos modelos preditivos.

Figura 9 – Balanceamento das Amostras do Atributo de Potabilidade



Fonte: Elaborada pelo Autor (2024).

A segunda base de dados foi fornecida pela Professora Roberta Pereira, como parte de um estudo de caso focado na análise da qualidade da água para o consumo humano do assentamento Jerusalém no município de Rubim-MG [2], localizado também no Baixo Vale do Jequitinhonha e Microrregião de Almenara-MG. Esta base de dados foi extraída de um levantamento local e contém os mesmos parâmetros físico-químicos, com exceção do atributo potabilidade, que não estava presente. Porém, essa coluna potabilidade foi incluída manualmente nessa base, validar e adicionar a classificação de potabilidade (0

[2] https://www.nucleodoconhecimento.com.br/engenharia-agricola/qualidade-da-agua

= Não Potável, 1 = Potável), através da análise nas amostras aplicando os padrões de qualidade da água estabelecidos, como os da Portaria GM/MS nº 888/2021[3]:

- pH: Deve estar na faixa de 6,0 a 9,5.
- Cloro: Limite máximo de 2,0 mg/L.
- Cloretos: Limite máximo de 250 mg/L.
- Dureza: Limite máximo de 500 mg/L CaCO3.
- Ferro: Limite máximo de 0,3 mg/L.
- Cor: Máximo de 15 mg/L PtCo.
- Turbidez: Máximo de 5 NTU.

As amostras da tabela da Figura 10, foram classificadas com base nos limites estabelecidos para cada parâmetro de qualidade da água. A tabela apresenta o Valor Máximo Permitido (VMP) e identifica três amostras para cada origem: chuva sem solução de hipoclorito de sódio (CSH), chuva tratada com solução (CH), poços artesianos (PA) e caminhão pipa (CP). Essa classificação permite avaliar a conformidade das amostras em relação aos padrões de potabilidade.

Figura 10 – Tabela de Parâmetros Físico-Químicos e Potabilidade de Amostras de Água Rubim – MG.

Amostra	pH	Cloro (mg/L Cl2)	Cloretos (mg/L Cl-)	Dureza Total (mg/L CaCO3)	Ferro (mg/L Fe)	Cor (mg/L PtCo)	Turbidez (NTU)	Potabilidade
CSH1	6,9	0,1	6,25	4,1	0,25	5	3	1
CSH2	7,1	0,1	2,45	4,6	0,25	3	22	0
CSH3	8,2	0,1	4,8	4,2	0,25	3	27	0
CH1	6,5	0,1	0,5	1,2	0,25	5	2	1
CH2	7,6	0,1	0,4	1,4	0,25	5	5	1
CH3	6,8	0,11	4,5	1,0	0,25	5	7	0
PA1	6,9	0,1	1,65	7,7	0,25	25	30	0
PA2	6,9	0,1	1,4	4,7	0,25	15	9	0
PA3	6,8	0,1	5,45	13,1	0,25	5	25	0
CP1	6,0	0,25	0,45	4,8	0,25	5	18	0
CP2	6,2	0,25	0,45	4,8	0,25	3	6	0
CP3	6,4	0,25	0,5	4,7	0,25	3	15	1
VMP	9,0	2,0	250	500	0,3	15	5	1

Fonte: Elaborada pelo Autor (2024).

Dentre os parâmetros apresentados na tabela para as amostras coletadas na região de Rubim-MG, observa-se que, ao integrar esses dados com a base principal de treino/teste

[3] https://bvsms.saude.gov.br/bvs/saudelegis/gm/2021/prt0888_07_05_2021.html

obtida do repositório Kaggle, apenas três variáveis foram identificadas como comuns entre as bases: pH, dureza e turbidez. Com isso, essa limitação em relação aos atributos disponíveis direcionou a escolha dos parâmetros utilizados no treinamento e validação dos modelos preditivos. Assim, a análise focada nesses três parâmetros foi essencial para garantir a consistência entre as bases, permitindo que os modelos fossem treinados com dados da base principal e depois validados com as amostras específicas da base de Rubim-MG.

6.2 Preparação dos Dados para Modelagem

A preparação dos dados é uma etapa fundamental na construção de modelos preditivos, pois a qualidade dos dados diretamente influencia a performance e a precisão dos modelos de aprendizado de máquina. Esta seção detalha as etapas seguidas para garantir que os dados estivessem prontos para a modelagem.

6.2.1 Tratamento de Dados Ausentes

Uma análise inicial foi realizada para identificar a presença de valores ausentes nas bases de dados coletadas, dado que esses valores podem impactar negativamente o desempenho dos modelos preditivos. O tratamento de dados ausentes foi conduzido com estratégias bem definidas, assegurando a integridade e consistência dos conjuntos de dados utilizados.

Primeiramente, identificaram-se as colunas em comum entre as bases de treino/teste e validação, permitindo o alinhamento dos conjuntos de dados com base nas variáveis compartilhadas. Essa etapa foi crucial para garantir que as análises subsequentes fossem realizadas em um formato consistente entre os dois conjuntos.

Em seguida, aplicou-se a técnica de imputação por média, amplamente utilizada em cenários de aprendizado de máquina para lidar com dados ausentes. A ferramenta utilizada foi a biblioteca scikit-learn, com a implementação do algoritmo *SimpleImputer*. Esse processo consistiu em duas etapas: o ajustamento do imputador aos dados da base de treino, para calcular as médias de cada coluna, seguido da aplicação das médias calculadas na imputação dos valores ausentes na base de treino e teste. A base de validação permaneceu separada e não foi utilizada durante esse processo, garantindo a integridade da validação do modelo.

Essa abordagem, além de assegurar a homogeneidade dos dados, foi essencial para evitar o viés que poderia ser introduzido ao remover variáveis ou registros inteiros. Assim, foi possível preservar o máximo de informação possível para a construção dos modelos preditivos, resultando em análises mais robustas e consistentes. A combinação dessas etapas contribuiu diretamente para a melhora da qualidade dos dados, assegurando que as análises preditivas fossem realizadas em um ambiente bem preparado e confiável.

6.2.2 Normalização/Padronização

A normalização e a padronização dos dados foram implementadas como parte fundamental do pré-processamento, visando melhorar o desempenho dos modelos de aprendizado de máquina. Estes processos ajudam a ajustar a escala das variáveis, tornando-as comparáveis e reduzindo o impacto de variáveis com amplitudes maiores nos cálculos dos algoritmos. Um dataset pode conter variáveis em diferentes escalas e, assim sendo, recomendase padronizar esses dados para uma mesma escala. Para isso, usamos a técnica da normalização (ENAP, 2020).

No contexto deste estudo, a normalização dos dados foi uma etapa essencial para garantir a consistência e a qualidade do pré-processamento, melhorando o desempenho dos modelos de aprendizado de máquina aplicados. Assim, a técnica utilizada foi o *StandardScaler*, da biblioteca scikit-learn, que transforma as variáveis para que tenham média zero e desvio padrão igual a um. Esse método foi escolhido por ser amplamente eficiente para algoritmos que utilizam medidas de distância ou que são sensíveis a escalas.

O processo de normalização foi realizado em dois conjuntos de dados: a base de treino/teste e a base de validação. O *StandardScaler* foi ajustado aos dados da base de treino para calcular os parâmetros de normalização (média e desvio padrão). Posteriormente, esses mesmos parâmetros foram aplicados à base de validação, assegurando que os dados fossem transformados de maneira consistente e evitando o vazamento de informações entre os conjuntos.

Essa abordagem é fundamental para reduzir o impacto de variáveis com amplitudes distintas nos cálculos dos modelos, permitindo que todas as características tenham o mesmo peso durante o treinamento e a validação. Ao padronizar as variáveis, evita-se que aquelas com maior amplitude dominem os processos de aprendizado, contribuindo para uma análise mais robusta e equilibrada.

A aplicação do *StandardScaler* foi automatizada utilizando as funções (*fit transform, transform)* do scikit-learn, garantindo eficiência e precisão no pré-processamento dos dados. Essa técnica desempenhou um papel crucial para a obtenção de resultados mais confiáveis e consistentes na avaliação dos modelos preditivos.

6.2.3 Balanceamento de Classes

O conjunto de dados de treino apresentou um desequilíbrio significativo entre as classes da variável alvo, o que poderia comprometer o desempenho dos modelos, favorecendo as classes majoritárias. Para lidar com esse problema, foi utilizada a técnica SMOTE (Synthetic Minority Oversampling Technique), que gera novas amostras sintéticas da classe minoritária com base em seus vizinhos mais próximos.

O SMOTE foi aplicado exclusivamente à base de treino padronizada, garantindo

que as proporções das classes fossem equilibradas para o treinamento dos modelos. O balanceamento foi implementado com a biblioteca *imblearn*, utilizando o método (*fit resample*) possibilitando a criação de novas amostras com base nos vizinhos mais próximos, equilibrando a distribuição das classes de forma uniforme, aumentando a representatividade da classe minoritária e, assim, reduzindo possíveis vieses nos resultados preditivos.

Essa etapa foi fundamental para assegurou uma análise justa, permitindo que os algoritmos desenvolvidos fossem capazes de lidar com as classes de maneira balanceada, otimizando métricas como precisão e recall, essenciais para a avaliação de modelos com classes desbalanceadas.

6.2.4 Redução de Dimensionalidade com PCA

A análise de componentes principais (PCA, Principal Component Analysis) foi aplicada como etapa de pré-processamento, com o objetivo de reduzir a dimensionalidade dos dados, preservando 95% da variância explicada. Essa técnica transforma variáveis originais em um conjunto menor de componentes principais, mantendo a maior parte das informações relevantes. O PCA é particularmente útil em contextos de alta dimensionalidade, reduzindo redundâncias e minimizando o risco de sobreajuste nos modelos preditivos.

O PCA foi implementado após o balanceamento dos dados com SMOTE, garantindo que as amostras geradas fossem consideradas. Utilizando a biblioteca scikit-learn, os dados normalizados foram ajustados para determinar automaticamente o número ideal de componentes principais, eliminando variáveis com baixa contribuição para a variância total.

Os componentes principais foram empregados tanto no treinamento dos modelos quanto na validação. Isso possibilitou análises mais eficientes, otimizando o desempenho dos algoritmos e destacando padrões relevantes nos dados. A técnica também contribuiu para a compreensão dos fatores que influenciam a potabilidade da água, tornando os resultados mais robustos.

O PCA foi escolhido por suas vantagens, tais como:

- Facilidade de visualização: Reduz a complexidade dos dados, permitindo uma análise mais clara das relações entre variáveis (JOLLIFFE; CADIMA, 2016).
- Eliminação de redundâncias: Combina variáveis correlacionadas em componentes principais, mantendo as informações mais relevantes (SHLENS, 2014).
- Melhoria no desempenho do modelo: Reduz o risco de overfitting, especialmente com poucos dados de teste (JOLLIFFE; CADIMA, 2016).

- Eficiência computacional: Diminui o número de variáveis, acelerando o processamento e treinamento dos modelos (MAATEN, 2008).

Portanto, o uso do PCA contribuiu para a simplificação dos dados, mantendo as características essenciais, melhorando a performance dos modelos e facilitar a interpretação dos resultados.

6.2.5 Divisão dos dados

A divisão dos dados é uma etapa crucial em projetos de aprendizado de máquina, pois garante que o modelo seja treinado, testado e validado em conjuntos distintos, aumentando sua capacidade de generalização. No presente estudo, a base de dados foi separada em três conjuntos principais: treino, teste e validação. O conjunto de treino foi utilizado para ajustar os modelos preditivos, enquanto o conjunto de teste serviu para uma avaliação inicial do desempenho. Já o conjunto de validação, composto por uma base independente coletada na região de Rubim-MG, foi utilizado para verificar a eficácia dos modelos ajustados em um cenário mais diverso e realista.

Para o conjunto de treino e teste, a base de dados *"water potability"* foi dividida na proporção de 70% para treino e 30% para teste, utilizando a técnica *"train test split"* da biblioteca scikit-learn. Essa divisão assegurou que os dados fossem distribuídos de forma balanceada, garantindo representatividade para cada classe.

Além disso, para lidar com a limitação de dados no conjunto de validação, foram empregadas estratégias de pré-processamento específicas. A validação cruzada k-fold também foi considerada durante os ajustes dos hiperparâmetros dos modelos, contribuindo para uma análise mais robusta e menos dependente de uma única divisão de dados. Essa abordagem aumenta a estabilidade dos resultados, reduzindo a dependência de uma única divisão de treino, teste e validação, o que é especialmente útil quando se possui uma base de validação pequena (BERRAR, 2019).

Esse processo metodológico garantiu que cada modelo fosse avaliado em múltiplos cenários, proporcionando maior confiabilidade aos resultados obtidos, especialmente ao utilizar a base de validação como um parâmetro final de comparação. Dessa forma, a abordagem adotada permitiu não apenas o treinamento eficiente dos modelos, mas também uma avaliação detalhada de sua capacidade de generalização para diferentes contextos.

6.3 Modelagem e Otimização dos Algoritmos ou Treinamento dos Modelos

A modelagem foi conduzida com o objetivo de explorar e validar o desempenho de diferentes algoritmos de aprendizado de máquina aplicados à classificação da potabilidade da água. Quatro algoritmos supervisionados principais foram selecionados: K-Nearest Neighbors (KNN), Random Forest, Support Vector Machine (SVM) e Árvore de Decisão. A escolha baseou-se na diversidade de abordagens e na compatibilidade com os dados, garantindo uma análise completa.

O KNN, por exemplo, é um algoritmo intuitivo e não paramétrico que classifica novas observações com base na proximidade de seus vizinhos mais próximos. Embora simples, ele é eficiente em capturar padrões complexos, especialmente em problemas com classes bem separadas no espaço de atributos (WITTEN et al., 2016).

O Random Forest foi escolhido por sua robustez ao combinar várias árvores de decisão, o que reduz o risco de overfitting e melhora a generalização do modelo. Este algoritmo é amplamente utilizado em tarefas de classificação devido à sua capacidade de lidar com dados de diferentes naturezas e à habilidade de identificar automaticamente variáveis relevantes (LOUPPE, 2015).

A SVM destaca-se pela eficácia em dados não linearmente separáveis e em alta dimensionalidade. Utilizando diferentes tipos de kernels, a SVM consegue criar hiperplanos que maximizam a margem de separação entre classes, o que a torna altamente indicada para problemas complexos e dados ruidosos (BURGES, 1998; PEDREGOSA, 2011).

Já a Árvore de Decisão foi incluída por sua interpretabilidade e simplicidade na criação de regras de decisão, auxiliando na identificação dos atributos mais relevantes para a classificação inicial e permitindo fácil comparação com outros modelos (MAIMON; ROKACH, 2014).

Os algoritmos foram ajustados e otimizados por meio das técnicas GridSearchCV e RandomizedSearchCV, explorando diferentes combinações de hiperparâmetros para maximizar o desempenho preditivo. Essa etapa foi essencial para identificar as melhores configurações de cada modelo, promovendo uma análise comparativa detalhada. Os principais aspectos abordados foram:

1. K-Nearest Neighbors (KNN):

    - Utilizado para sua simplicidade e eficiência em problemas de classificação, o KNN foi ajustado para otimizar o número de vizinhos *(n-neighbors)*, com valores variando de 1 a 50.

- A métrica f1-score foi escolhida como critério principal de avaliação, dado o equilíbrio necessário entre precisão e recall em classes desbalanceadas.

2. Random Forest:

   - Este algoritmo foi otimizado para explorar o número de árvores *(n-estimators)*, profundidade máxima *(max-depth)*, e critérios de divisão. Sua robustez permitiu lidar eficientemente com a diversidade dos dados.
   - A técnica GridSearchCV foi utilizada para ajustar hiperparâmetros, garantindo que os melhores modelos fossem aplicados tanto no conjunto de teste quanto na base de validação.

3. Árvore de Decisão:

   - O ajuste foi realizado com RandomizedSearchCV, permitindo uma busca mais ampla e eficiente por configurações ideais, como critérios *(gini e entropy)*, profundidade máxima e número mínimo de amostras por divisão.
   - O balanceamento de classes foi realizado com SMOTE antes do treinamento, assegurando uma avaliação mais justa e reduzindo os efeitos do desbalanceamento dos dados.

4. Support Vector Machine (SVM):

   - A SVM foi implementada com um pipeline, integrando normalização dos dados e ajuste de hiperparâmetros.
   - A busca incluiu valores para o coeficiente *(C)*, tipo de kernel *(rbf, poly e sigmoid)* e gama *(gamma)*, maximizando a separação entre as classes nos dados de alta dimensionalidade.

Na seleção dos algoritmos KNN (K-Nearest Neighbors), Random Forest, SVM (Support Vector Machine) e Árvore de Decisão, considerou-se a diversidade de técnicas que cada um oferece para modelagem de classificação supervisionada e a compatibilidade com dados, como os de qualidade da água.

Os modelos ajustados foram avaliados nos seguintes conjuntos:

- Conjunto de Teste: Composto por uma divisão da base principal *"water potability"*, utilizado para medir o desempenho preditivo em dados não vistos durante o treinamento.

- Base de Validação: Amostras externas coletadas na região de Rubim-MG, aplicadas para validar a generalização dos modelos em um contexto real.

Após o treinamento, os modelos foram avaliados utilizando a validação cruzada k-fold, que divide os dados em múltiplos subconjuntos para treinamento e teste (ou validação), fornecendo uma avaliação mais confiável do desempenho geral. A matriz de confusão foi empregada para identificar verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos, servindo como base para as métricas detalhadas no relatório de classificação, a fim de garantir uma análise detalhada e confiável da eficácia dos algoritmos na classificação dos dados de qualidade da água. As métricas empregadas incluem a acurácia, precisão *(precision)*, taxa de verdadeiro positivo *(recall)*, F1-score, Curva ROC e AUC (Área Sob a Curva).

6.4 Recursos Tecnológicos e Ferramentas Utilizadas

O desenvolvimento deste estudo foi possível graças ao uso de ferramentas computacionais amplamente reconhecidas no campo do aprendizado de máquina e análise de dados. Essas tecnologias permitiram a manipulação eficiente de informações, garantindo precisão e rapidez na implementação dos modelos preditivos. Ao utilizar um conjunto de bibliotecas e plataformas, foi possível integrar técnicas avançadas de processamento de dados e visualização, otimizando o desempenho das análises realizadas. As principais ferramentas computacionais utilizadas foram:

- Python: Linguagem de programação versátil e amplamente usada em ciência de dados devido à sua simplicidade e vasta gama de bibliotecas. Python foi a base para toda a implementação do estudo (VANDERPLAS, 2016).
- Scikit-learn: Biblioteca fundamental para aprendizado de máquina em Python, oferece ferramentas para pré-processamento, modelagem, validação cruzada e avaliação de métricas. Foi utilizada para o treinamento e ajuste de modelos, como Random Forest e KNN (PEDREGOSA, 2011).
- Pandas: Biblioteca essencial para manipulação e análise de dados estruturados, permitiu o tratamento e organização das bases de dados, incluindo limpeza e transformação dos dados para entrada nos algoritmos (MCKINNEY et al., 2010).
- Numpy: Utilizada para operações numéricas eficientes, especialmente em arrays e matrizes. Foi essencial no pré-processamento de dados e integração com outras bibliotecas (HARRIS et al., 2020).

- Matplotlib e Seaborn: Bibliotecas de visualização de dados empregadas para gerar gráficos e representações visuais das métricas de desempenho dos modelos, facilitando a análise de resultados (WASKOM, 2021).
- Colab: Ferramenta baseada em nuvem do Google, permitiu o desenvolvimento do código com acesso a recursos computacionais avançados, como GPUs, e facilitou a colaboração e o armazenamento dos experimentos [4].

Essas ferramentas permitiram uma integração eficiente entre os processos de manipulação de dados, implementação de modelos e análise de resultados, garantindo resultados confiáveis e que possam ser facilmente reproduzidos.

[4] https://colab.research.google.com/

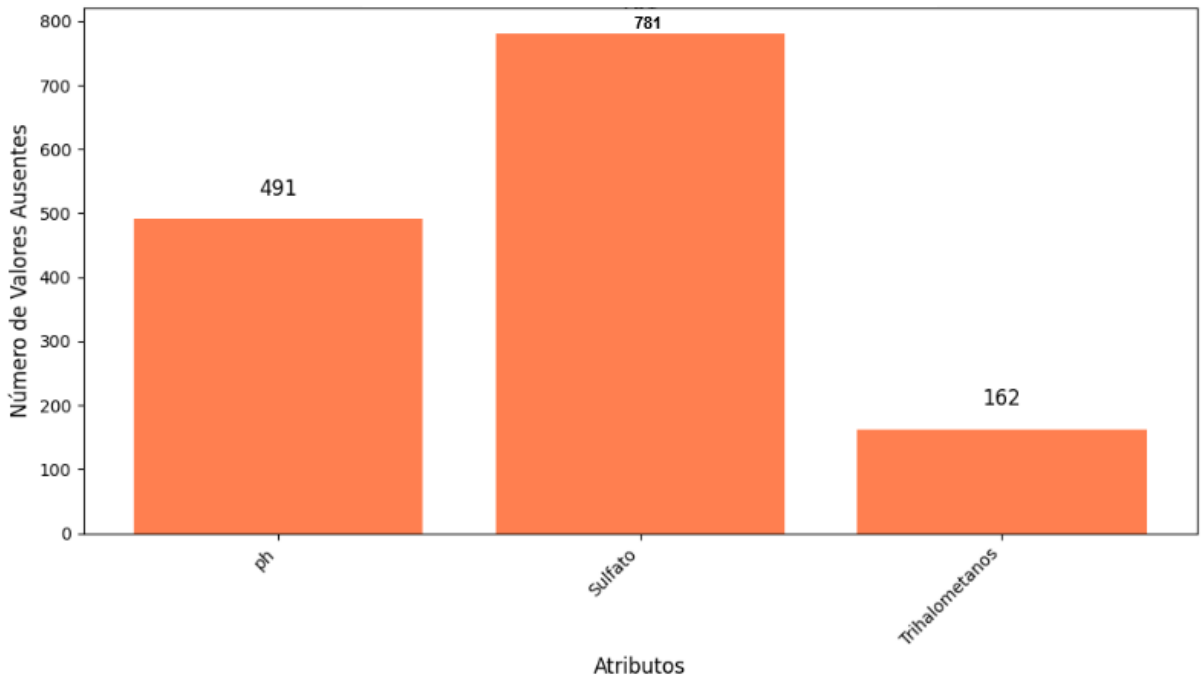
7 Resultados e Discussões

Este capítulo apresenta os resultados obtidos nas análises realizadas, com foco no desempenho dos algoritmos selecionados e nas métricas utilizadas para avaliar sua eficácia. As etapas de pré-processamento e análise exploratória desempenharam um papel crucial na preparação do conjunto de dados, permitindo interpretações confiáveis e robustas.

Durante a execução no ambiente Colab, foram empregadas bibliotecas como Pandas e Scikit-learn para o pré-processamento das bases de treino, teste e validação. A análise exploratória destacou aspectos essenciais, como a distribuição de valores ausentes por atributo, evidenciando a necessidade de imputação para garantir a integridade dos modelos.

A Figura 11 ilustra as características da base de dados, como a proporção de valores ausentes por atributo, destacando os desafios e as soluções aplicadas na preparação dos dados.

Figura 11 – Proporção de dados ausentes por atributo na base de treino/teste.



Fonte: Elaborada pelo Autor (2024).

Com isso, o atributo pH apresentou 491 dados ausentes, Sulfato 781 e Trihalometanos 162, totalizando 1.434 valores ausentes. Essa identificação foi crucial para iniciar o trabalho com as variáveis comuns entre as duas bases de dados e proceder à imputação dos valores ausentes utilizando a média, assegurando a qualidade necessária para as etapas de análise e modelagem subsequentes.

7.1 Análise Geral dos Resultados

Após o pré-processamento, que incluiu a normalização, imputação de valores ausentes, e aplicação do SMOTE e PCA, os algoritmos foram treinados e testados utilizando a base principal (treino/teste). Além disso, os modelos foram validados com uma segunda base de dados composta por amostras coletadas na região de Rubim-MG.

- O modelo KNN apresentou desempenho moderado, com uma acurácia de 6% no conjunto de teste e resultados superiores na base de validação (85%). A taxa de recall para a classe 1 foi de 0.66 no conjunto de teste, mas o recall para a classe 0 foi de apenas 0.57, mostrando desempenho desigual. A validação cruzada indicou uma média de acurácia de 63,39%. O KNN se destacou na detecção da classe positiva (potável), mas teve um desempenho misto na classe negativa.
- A Random Forest obteve uma acurácia de 61% no conjunto de teste e 85% na base de validação. A matriz de confusão da base de validação indicou uma precisão de 0.88 na classe 0 e 0.80 na classe 1, com um recall um pouco mais baixo para a classe 1. A média de acurácia na validação cruzada foi de 63,21%. Embora tenha mostrado uma boa capacidade de generalização, o modelo teve algumas limitações na detecção de certas classes.
- A Árvore de Decisão teve um desempenho inferior, com acurácia de apenas 60% no conjunto de teste. Na base de validação, a acurácia foi de 31%, com recall extremamente baixo, especialmente para a classe 0. A média de acurácia na validação cruzada foi de 58,31%, refletindo sua limitação na generalização. Esse modelo demonstrou dificuldades em lidar com dados de alta variabilidade sem um processamento adicional.
- O SVM apresentou o desempenho mais baixo, com uma acurácia de 55% no conjunto de teste e 62% na base de validação. No entanto, o recall para a classe 1 foi zero, o que significa que o modelo falhou em detectar instâncias de água potável. Apesar de uma média de acurácia de 56% na validação cruzada, o modelo teve dificuldades em separar as classes, especialmente na base de validação, com baixa pontuação em F1-Score e precisão para a classe positiva.

A seguir, são apresentados os resultados das matrizes de confusão para os conjuntos de teste e validação, com a performance de cada algoritmo avaliada por meio da distribuição de acertos e erros. As matrizes fornecem uma visão detalhada sobre a capacidade de cada modelo em classificar corretamente as amostras, destacando os valores de verdadeiros positivos, falsos positivos, verdadeiros negativos e falsos negativos. Essas informações são essenciais para entender o desempenho de cada algoritmo em relação à potabilidade da água.

Figura 12 – Resultados das Matrizes de Confusão nos Conjuntos de Teste e Validação para Cada Algoritmo

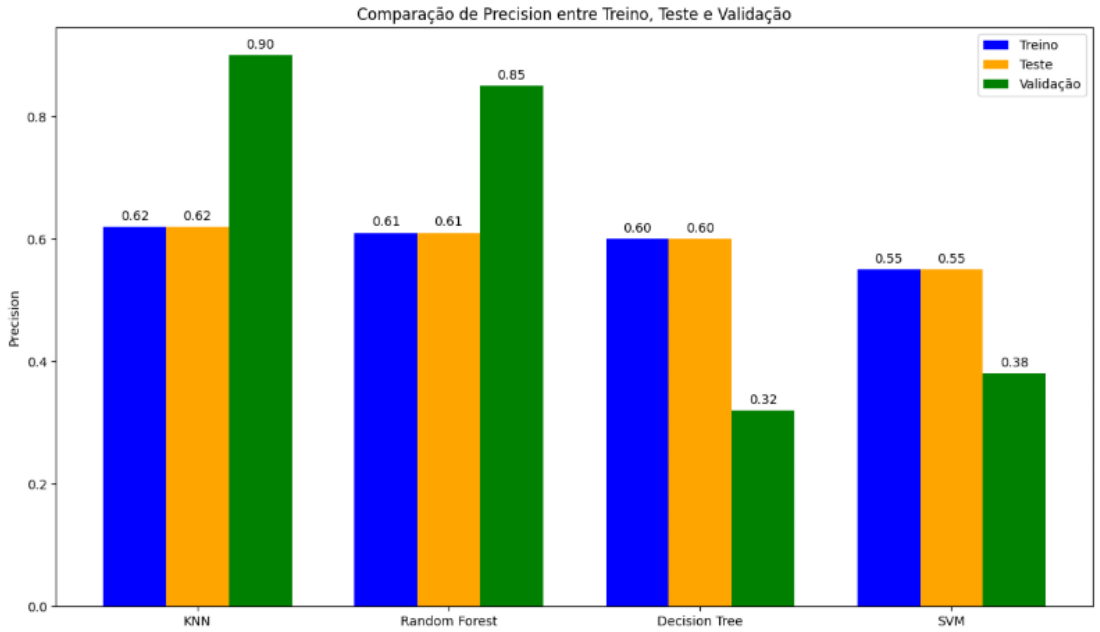
Algoritmo	Conjunto	VP (0)	FN (0)	FP (1)	VN (1)
KNN	Teste	344	257	201	397
	Validação	8	0	2	3
Random Forest	Teste	357	244	226	372
	Validação	7	1	1	4
Árvore de Decisão	Teste	346	255	229	369
	Validação	1	7	2	3
SVM	Teste	328	273	261	337
	Validação	8	0	5	0

Fonte: Elaborada pelo Autor (2024).

Os gráficos de precisão na Figura 13 e recall na Figura 14, o eixo X representa os diferentes algoritmos de Machine Learning, e o eixo Y representa as métricas. A precisão indica a porcentagem de exemplos classificados como positivos que são realmente positivos. O recall mostra a proporção de exemplos positivos que foram corretamente identificados pelo modelo.

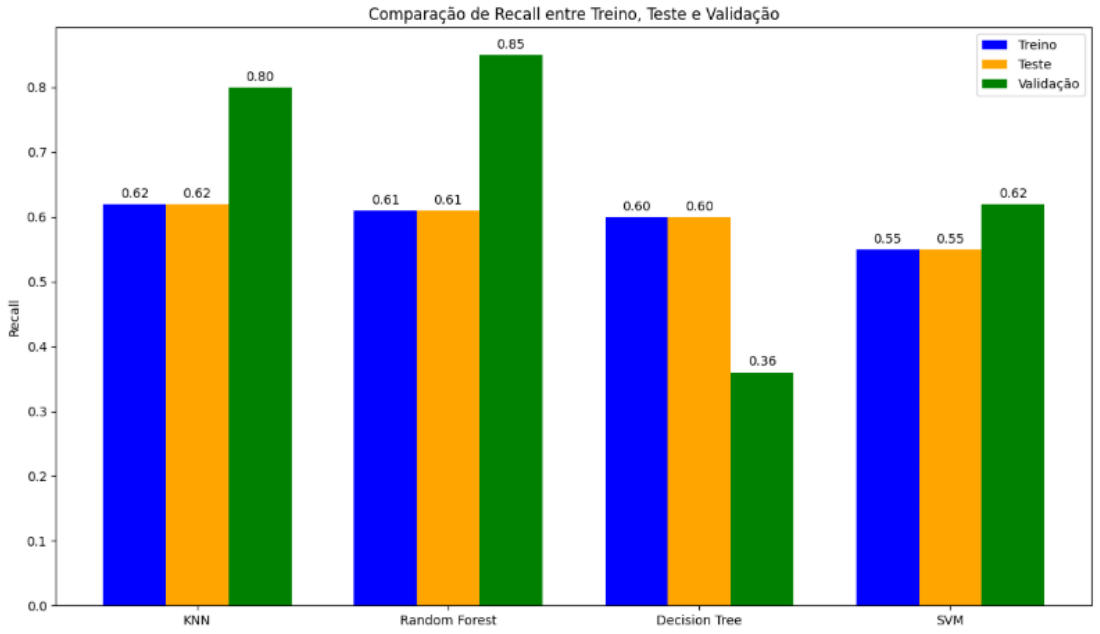
Com isso, foram avaliados por meio da média macro, no qual, o KNN destacou-se como o modelo com melhor desempenho, alcançando 62% de precisão e recall no treino/teste e registrando 90% de precisão e 80% de recall na validação, evidenciando sua eficácia na identificação de exemplos positivos. O Random Forest também apresentou resultados satisfatórios, com 61% em ambas as métricas no treino/teste e 85% de precisão e recall na validação, demonstrando uma boa capacidade de generalização, embora inferior ao KNN. Por outro lado, a Árvore de Decisão apresentou resultados negativos, com 60% de precisão e recall no treino/teste e um desempenho significativamente inferior na validação, com 32% de precisão e 36% de recall, indicando dificuldades em generalizar os padrões aprendidos. Já o SVM mostrou limitações, obtendo 55% de precisão e recall no treino/teste, enquanto na validação apresentou 38% de precisão e 62% de recall, refletindo sua dificuldade em classificar corretamente os exemplos positivos.

Figura 13 – Precisão por Algoritmo



Fonte: Elaborada pelo Autor (2024).

Figura 14 – Recall por Algoritmo

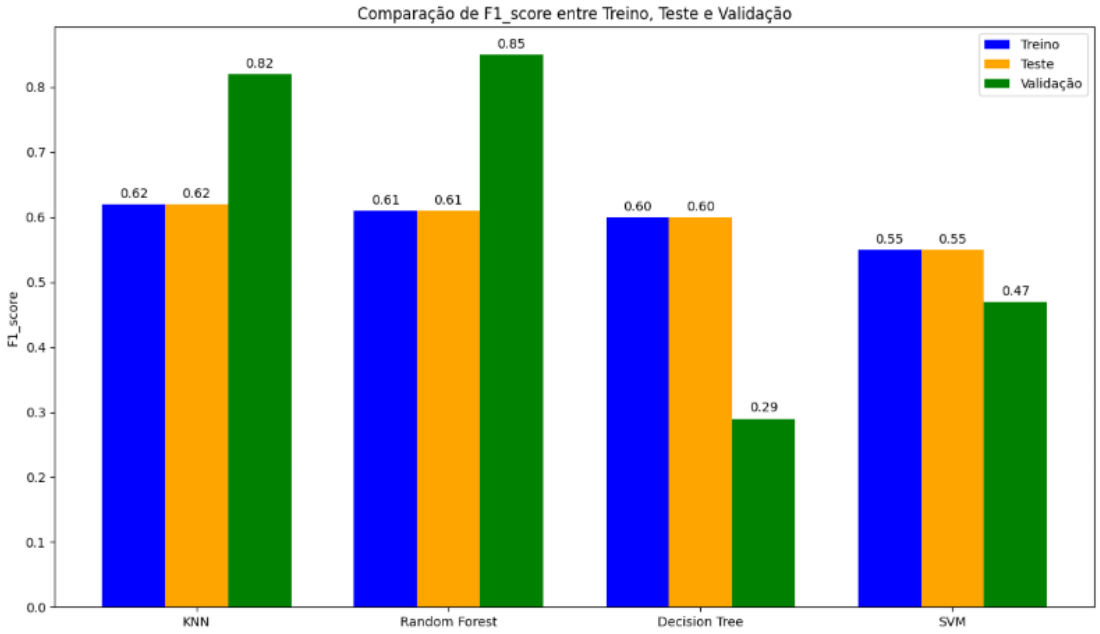


Fonte: Elaborada pelo Autor (2024).

Em F1-Score na Figura 15, o eixo X representa os diferentes algoritmos, enquanto o eixo Y indica o valor do F1-Score, que é a média harmônica entre precisão e recall, refletindo a capacidade do modelo de identificar corretamente os exemplos positivos e minimizar falsos positivos. Observou-se que o Random Forest obteve F1-Score de 0,61

no treino/teste e 0,85 na validação, indicando bom equilíbrio entre precisão e recall, especialmente na validação. O KNN obteve 0,62 no treino/teste e 0,82 na validação, apresentando desempenho sólido, porém ligeiramente inferior ao Random Forest. O SVM apresentou 0,55 no treino/teste e 0,47 na validação, sugerindo dificuldades em capturar exemplos positivos. Já a Árvore de Decisão obteve 0,60 no treino/teste e 0,29 na validação, evidenciando desempenho insatisfatório em ambas as métricas.

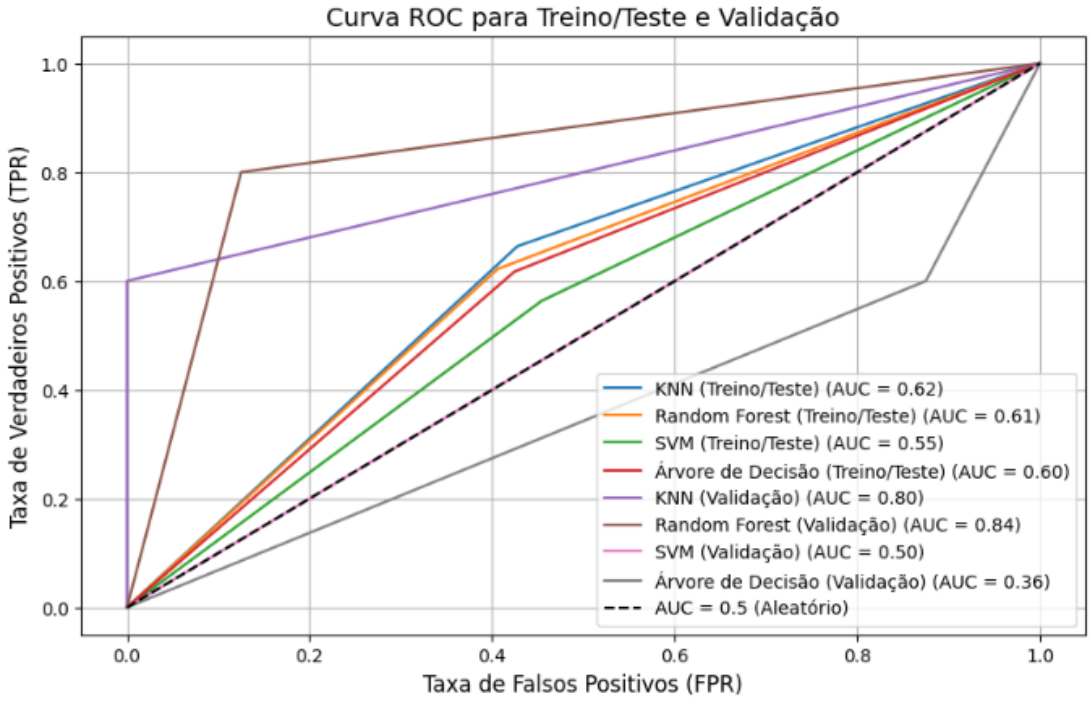
Figura 15 – Comparação do F1-Score



Fonte: Elaborada pelo Autor (2024).

A curva ROC na Figura 16, que representa a taxa de falsos positivos no eixo X e a taxa de verdadeiros positivos no eixo Y, foi analisada para avaliar o desempenho dos modelos. Para o KNN, a área sob a curva (AUC) foi de 0,62 no treino/teste e 0,80 na validação, indicando um bom desempenho em distinguir entre as classes, com um desempenho superior na validação. O Random Forest obteve AUC de 0,61 no treino/teste e 0,84 na validação, também mostrando bom desempenho. No SVM, a AUC foi de 0,55 no treino/teste e 0,50 na validação, sugerindo que o modelo teve dificuldades em classificar corretamente as classes. Já a Árvore de Decisão apresentou AUC de 0,60 no treino/teste e 0,36 na validação, indicando um desempenho abaixo do esperado, próximo ao acaso.

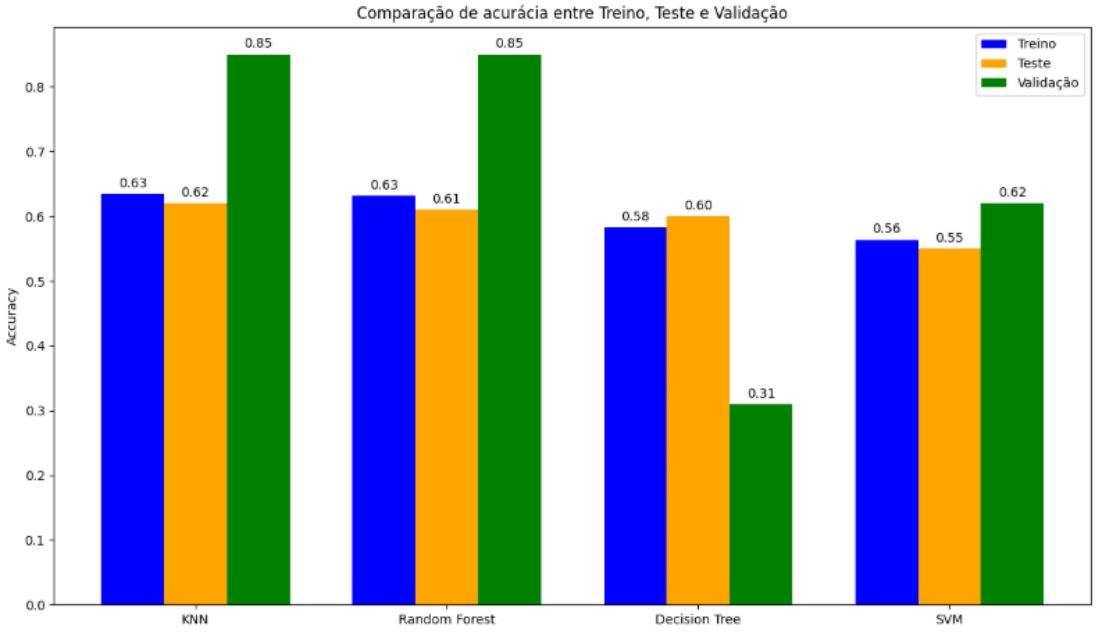
Figura 16 – Curva ROC



Fonte: Elaborada pelo Autor (2024).

O gráfico da Figura 17 ilustra a comparação das acurácias obtidas pelos modelos KNN, Random Forest, Decision Tree e SVM nos conjuntos de treino, teste e validação. Os resultados revelam diferenças significativas entre os desempenhos dos algoritmos, permitindo identificar pontos fortes e limitações de cada abordagem:

Figura 17 – Comparação de Acurácia entre Modelos (Teste vs Validação)



Fonte: Elaborada pelo Autor (2024).

- O KNN e o Random Forest apresentaram as melhores acurácias no conjunto de validação, com valores de 0.85, indicando um desempenho consistente e alta capacidade preditiva para os dados utilizados.
- A Árvore de Decisão, apesar de alcançar boa acurácia no treino e teste, mostrou uma queda acentuada na validação (0.31), evidenciando problemas de overfitting.
- O modelo SVM apresentou um desempenho intermediário em todos os conjuntos, com valores de acurácia variando de 0.55 a 0.62, sugerindo uma estabilidade maior, mas com menor precisão em relação ao KNN e ao Random Forest.

7.2 Considerações Finais

A análise dos resultados demonstrou que, apesar das limitações da base de validação, os modelos aplicados apresentaram desempenho satisfatório, especialmente em contextos desafiadores. A base de validação, composta por apenas 13 amostras e três parâmetros comuns com a base de treino/teste, dificultou a generalização dos modelos, impactando algumas métricas, como a acurácia e o recall.

Comparando com o trabalho relacionado "Uso de Modelos de Aprendizado Supervisionado para Classificação da Potabilidade da Água", que utilizou uma única base de dados abrangente e obteve uma acurácia de 87% com o SVM, os resultados deste estudo apresentaram características distintas. No trabalho relacionado, o SVM foi o algoritmo de melhor desempenho. Já neste estudo, o KNN destacou-se como o modelo mais eficaz, alcançando 63% de acurácia no treino, 62% no teste e 85% na validação. Essa diferença está diretamente ligada ao uso de duas bases de dados distintas, sendo que a base de validação tinha um número limitado de amostras e parâmetros em comum com a base de treino.

Embora algumas métricas tenham ficado abaixo do esperado, os modelos empregados demonstraram superioridade em relação a métodos tradicionais de análise, sobretudo na capacidade de lidar com bases heterogêneas e no aproveitamento de múltiplos parâmetros. O aprendizado de máquina mostrou-se vantajoso para integrar e processar dados de diferentes origens, superando limitações práticas típicas de métodos convencionais.

Portanto, com uma base de dados maior e mais parâmetros compartilhados entre as bases de treino, teste e validação, os modelos poderiam apresentar resultados ainda mais consistentes e generalizáveis. Esses achados reforçam a importância de investir em bases de dados robustas e completas, bem como em técnicas avançadas de pré-processamento e modelagem, para potencializar o desempenho e a aplicabilidade dos modelos no contexto da análise da qualidade da água.

7.2.1 Trabalhos Futuros

Embora este estudo tenha sido conduzido com um enfoque acadêmico, com o objetivo de explorar a aplicação de modelos preditivos na análise da qualidade da água, futuros trabalhos podem ampliar as abordagens utilizadas, focando na melhoria da qualidade dos dados. As limitações encontradas, como o tamanho reduzido da base de validação e a escassez de parâmetros comuns entre as bases de dados, impactaram diretamente o desempenho dos modelos neste estudo.

Trabalhos futuros podem expandir a pesquisa utilizando bases de dados mais abrangentes, com maior número de amostras e parâmetros consistentes entre os conjuntos de treino, teste e validação. Além disso, explorar a integração de outras técnicas de aprendizado de máquina, como redes neurais ou métodos de ensemble, pode aprimorar ainda mais a precisão dos modelos.

A validação dos modelos em cenários mais próximos à realidade, com dados variados de diferentes regiões, contribuiria para uma análise mais robusta e para o aprimoramento da generalização dos modelos.

Finalmente, a aplicação de técnicas de otimização de parâmetros, como o uso de algoritmos de busca mais sofisticados, poderia potencializar o desempenho dos modelos, permitindo um ajuste mais fino e uma melhor adaptação aos dados de diferentes origens. Isso abriria caminho para futuras pesquisas que poderiam gerar modelos preditivos de qualidade da água com maior aplicabilidade prática.

Referências

AKKARABOYINA, M. K.; RAJU, B. A comparative study of water quality indices of river godavari. *International Journal of Engineering Research and Development*, v. 2, n. 3, p. 29–34, 2012.

ALTMAN, N. S. An introduction to kernel and nearest-neighbor nonparametric regression. *The American Statistician*, Taylor & Francis, v. 46, n. 3, p. 175–185, 1992.

ANA. República Federativa do Brasil. 2018.

APHA. *Standard methods for the examination of water and wastewater*. [S.l.]: American Public Health Association., 2005. v. 6.

BERGSTRA, J.; BENGIO, Y. Random search for hyper-parameter optimization. *Journal of machine learning research*, v. 13, n. 2, 2012.

BERRAR. 2019. Disponível em: http://berrar.com/resources/Berrar_EBCB_2nd_edition_Cross-validation_preprint.pdf.

BIANCO, A. M.; BOENTE, G.; PARDO-FERNáNDEZ, J. C. *ROC curve analysis for functional markers*. arXiv, 2024. ArXiv:2407.20929. Disponível em: http://arxiv.org/abs/2407.20929.

BRASIL. *Portaria_Consolidacao_5_28_SETEMBRO_2017.pdf*. 2017. Disponível em: https://portalsinan.saude.gov.br/images/documentos/Legislacoes/Portaria_Consolidacao_5_28_SETEMBRO_2017.pdf.

BRASIL. *Minist rio da Sa de*. 2021. Disponível em: https://bvsms.saude.gov.br/bvs/saudelegis/gm/2021/prt0888_07_05_2021.html.

BRAUN, C. L. Why is water blue? *J. Chem. Educ.*, v. 70, n. 8, p. 612, 1993. Disponível em: http://www.dartmouth.edu/~etrnsfer/water.html.

BREIMAN, L. *Classification and regression trees*. [S.l.]: Routledge, 2017.

BURGES, C. J. A tutorial on support vector machines for pattern recognition. *Data mining and knowledge discovery*, Springer, v. 2, n. 2, p. 121–167, 1998.

CETESB. Companhia ambiental do estado de são paulo. *Significado ambiental e sanitário das variáveis de qualidade das águas e dos sedimentos e metodologias analíticas e de amostragem. São Paulo: CETESB*, 2009.

CHAGAS, M. G. EcoWater, realizando o biomonitoramento da qualidade da água de forma inteligente. 2017.

CORTES, C. Support-vector networks. *Machine Learning*, 1995.

COVER, T.; HART, P. Nearest neighbor pattern classification. *IEEE transactions on information theory*, IEEE, v. 13, n. 1, p. 21–27, 1967.

CUTLER, D. R. et al. Random forests for classification in ecology. *Ecology*, Wiley Online Library, v. 88, n. 11, p. 2783–2792, 2007.

DOMINGOS, P. *The master algorithm: How the quest for the ultimate learning machine will remake our world*. [S.l.]: Basic Books, 2015.

ENAP. 2020. Disponível em: https://repositorio.enap.gov.br/bitstream/1/7872/3/Mod3%20Fundamentos%20de%20Machine%20Learning.pdf.

ESCOVEDO, T. *Escovedo*. 2020. Disponível em: https://tatianaesc.medium.com/machine-learning-conceitos-e-modelos-f0373bf4f445.

FEWELL, M. P. *Uncertainties in ROC (Receiver Operating Characteristic) Curves Derived from Counting Data*. arXiv, 2024. ArXiv:2406.11396. Disponível em: http://arxiv.org/abs/2406.11396.

FUSATI. *Água Potável e Seu Tratamento*. 2021. Disponível em: https://www.fusati.com.br/agua-potavel-e-seu-tratamento/.

GALVÃO, M. C. B. O levantamento author=Galvão, Maria Cristiane Barbosa,bibliográfico e a pesquisa científica. *Fundamentos de epidemiologia. 2ed. A*, v. 398, p. 1–377, 2010.

GÉRON, A. *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow*. [S.l.]: "O'Reilly Media, Inc.", 2022.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. MIT Press, 2016. (Adaptive Computation and Machine Learning series). ISBN 978-0-262-03561-3. Disponível em: https://books.google.com.br/books?id=Np9SDQAAQBAJ.

HAN, J.; KAMBER, M.; PEI, J. Data mining: Concepts and. *Techniques, Waltham: Morgan Kaufmann Publishers*, 2012.

HAN, J.; PEI, J.; TONG, H. *Data mining: concepts and techniques*. [S.l.]: Morgan kaufmann, 2022.

HARRIS, C. R. et al. Array programming with numpy. *Nature*, Nature Publishing Group UK London, v. 585, n. 7825, p. 357–362, 2020.

HASTIE, T. et al. *The elements of statistical learning: data mining, inference, and prediction*. [S.l.]: Springer, 2009. v. 2.

JAMES, G. et al. *An introduction to statistical learning*. [S.l.]: Springer, 2013. v. 112.

JAVATPOINT. 2022. Disponível em: https://www.javatpoint.com/types-of-machine-learning.

JOLLIFFE, I. T.; CADIMA, J. Principal component analysis: a review and recent developments. *Philosophical transactions of the royal society A: Mathematical, Physical and Engineering Sciences*, the Royal Society publishing, v. 374, n. 2065, p. 20150202, 2016.

KARPINSKI. 2018. Disponível em: https://www.linkedin.com/pulse/machine-learning-pt-3-descomplicando-matriz-de-e-recall-karpinski/.

KUHN, M. *Applied predictive modeling*. [S.l.]: Springer, 2013.

LEMAÃŽTRE, G.; NOGUEIRA, F.; ARIDAS, C. K. Imbalanced-learn: A python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of machine learning research*, v. 18, n. 17, p. 1–5, 2017.

LIAW, A.; WIENER, M. et al. Classification and regression by randomforest. *R news*, v. 2, n. 3, p. 18–22, 2002.

LOGUNOVA. 2022. Disponível em: https://serokell.io/blog/random-forest-classification.

LOUPPE, G. *Understanding Random Forests: From Theory to Practice*. arXiv, 2015. ArXiv:1407.7502. Disponível em: http://arxiv.org/abs/1407.7502.

LUCAS, H. B. *Machine Learning from scratch: Implementando o SVM (Máquinas de Vetores de Suporte) em Python*. 2024. Disponível em: https://iacomcafe.com.br/implementando-svm-do-zero/.

MAATEN. 2008. Disponível em: https://www.jmlr.org/papers/volume9/vandermaaten08a/vandermaaten08a.pdf.

MAIMON, O. Z.; ROKACH, L. *Data mining with decision trees: theory and applications*. [S.l.]: World scientific, 2014. v. 81.

MANNING, C. D. *Introduction to information retrieval*. [S.l.]: Cambridge university press, 2008.

MARIANO. 2021. Disponível em: https://bioinfo.com.br/metricas-de-avaliacao-em-machine-learning-acuracia-sensibilidade-precisao-especificidade-e-f-score/.

MCKINNEY, W. Data structures for statistical computing in python. *Proceedings of the 9th Python in Science Conference*, 01 2010.

MCKINNEY, W. et al. Data structures for statistical computing in python. In: *SciPy*. [S.l.: s.n.], 2010. v. 445, n. 1, p. 51–56.

MINISTERIO. *vigilancia_controle_qualidade_agua.pdf*. 2006. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/vigilancia_controle_qualidade_agua.pdf.

MáQUINA, H. *Aprenda como montar uma árvore de decisão*. 2020. Disponível em: https://www.homemmaquina.com.br/como-montar-uma-arvore-de-decisao/.

OMS. *Guidelines for drinking-water quality: fourth edition incorporating first addendum*. 4th ed + 1st add. ed. Geneva: World Health Organization, 2017. ISBN 978-92-4-154995-0. Disponível em: https://iris.who.int/handle/10665/254637.

PEDREGOSA, F. Scikit-learn: Machine learning in python fabian. *Journal of machine learning research*, v. 12, p. 2825, 2011.

PORTO, W. W. Uso de Modelos de Aprendizado Supervisionado para Classificação da Potabilidade da Água. 2024.

POWERS, D. M. Evaluation: from precision, recall and f-measure to roc, informedness, markedness and correlation. *arXiv preprint arXiv:2010.16061*, 2020.

PROVOST, F. *Data Science for Business: What you need to know about data mining and data-analytic thinking*. [S.l.]: O'Reilly Media, Inc, 2013. v. 355.

PYLE, D. *Data preparation for data mining*. [S.l.]: morgan kaufmann, 1999.

REIS, A. C. P.; GAMA, E. M.; MATOS, R. P. DETERMINAÇÃO DOS PARÂMETROS FÍSICO-QUÍMICOS DA ÁGUA DO RIO JEQUITINHONHA NA CIDADE DE ALMENARA-MG. *RECIMA21 - Revista Científica Multidisciplinar - ISSN 2675-6218*, v. 2, n. 11, p. e211942, nov. 2021. ISSN 2675-6218. Disponível em: https://recima21.com.br/index.php/recima21/article/view/942.

SAKURAI. 2024. Disponível em: https://www.javatpoint.com/types-of-machine-learning.

SAMMUT, C.; WEBB, G. I. *Encyclopedia of machine learning*. [S.l.]: Springer Science & Business Media, 2011.

SANTOS, H. G. d. et al. Machine learning para análises preditivas em saúde: exemplo de aplicação para predizer óbito em idosos de são paulo, brasil. *Cadernos De saúde pública*, SciELO Public Health, v. 35, p. e00050818, 2019.

SHLENS, J. *A Tutorial on Principal Component Analysis*. arXiv, 2014. ArXiv:1404.1100. Disponível em: http://arxiv.org/abs/1404.1100.

SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information processing & management*, Elsevier, v. 45, n. 4, p. 427–437, 2009.

STEINER, M. T. A. et al. Abordagem de um problema médico por meio do processo de KDD com ênfase à análise exploratória dos dados. *Gestão & Produção*, v. 13, p. 325–337, maio 2006. ISSN 0104-530X, 1806-9649. Publisher: Universidade Federal de São Carlos. Disponível em: http://www.scielo.br/j/gp/a/gC9RkgLD8B8FffPsNhBYWkB/?lang=pt.

TUNDISI, T. M. *Limnologia*. [S.l.]: Oficina de textos, 2016.

VANDERPLAS, J. *Python data science handbook: Essential tools for working with data*. [S.l.]: "O'Reilly Media, Inc.", 2016.

VINICIUSSEGATTO. *SVM, ou Support Vector Machine*. 2023. Disponível em: https://medium.com/liga-mackenzie-de-ia-ci%C3%AAncia-de-dados/svm-ou-support-vector-machine-7efcabdcc7be.

WASKOM, M. L. Seaborn: statistical data visualization. *Journal of Open Source Software*, v. 6, n. 60, p. 3021, 2021.

WITTEN, I. et al. *Data Mining: Practical Machine Learning Tools and Techniques*. Morgan Kaufmann, 2016. (The Morgan Kaufmann Series in Data Management Systems). ISBN 9780128043578. Disponível em: https://books.google.com.br/books?id=1SylCgAAQBAJ.